Κεφάλαιο 4

ΑΝΑΔΡΟΜΙΚΟΙ ΑΛΓΟΡΙΘΜΟΙ ΠΡΟΣΔΙΟΡΙΣΜΟΥ ΠΑΡΑΜΕΤΡΩΝ

Στο προηγούμενο κεφάλαιο ασχοληθήκαμε με τεχνικές προσδιορισμού των παραμέτρων ενός μοντέλου, όταν έχουμε στην διάθεσή μας N το πλήθος παρελθοντικών μετρήσεων των εισόδων και των εξόδων του πραγματικού συστήματος. Χαρακτηριστικό των αλγορίθμων που ανήκουν στην κατηγορία αυτή είναι ότι δεν μπορούν να εκτελεστούν σε πραγματικό χρόνο. Είναι όπως λέμε `off-line` αλγόριθμοι.

Υπάρχουν εφαρμογές που απαιτούν την `on-line` δημιουργία ενός μοντέλου του συστήματος, κατά την διάρκεια δηλαδή της λειτουργίας του. Τυπικές περιπτώσεις είναι ο προσαρμοστικός έλεγχος συστημάτων (`adaptive control`), η πρόβλεψη (`prediction`) της απόκρησης συστημάτων, η ανίχνευση και αναγνώριση βλαβών σε δυναμικά συστήματα (`fault detection and identification`) κ.α.

Οι αλγόριθμοι προσδιορισμού των παραμέτρων του μοντέλου που χρησιμοποιούνται στις περιπτώσεις αυτές πρέπει να είναι υπολογιστικά απλοί, ώστε η επεξεργασία των μετρήσεων του συστήματος που λαμβάνονται μια χρονική στιγμή να έχει ολοκληρωθεί με βεβαιότητα, πριν λάβει χώρα η επόμενη δειγματοληψία. Διαφορετικά, η κατασκευή του μοντέλου δεν μπορεί να αντιμετωπίσει τον ρυθμό εισροής πληροφοριών. Αλγόριθμοι που πληρούν την παραπάνω προϋπόθεση ονομάζονται *αναδρομικοί* (`recursive`), ή *πραγματικού χρόνου* (`real time`), ή `on-line`, ή *προσαρμοστικοί αλγόριθμοι εκτίμησης παραμέτρων* (`adaptive parameter estimation`). Στο κεφάλαιο αυτό θα μελετήσουμε αλγορίθμους προσδιορισμού των παραμέτρων ενός μοντέλου αναδρομικού τύπου. Θα δούμε τις ιδιότητές τους, τα πλεονεκτήματα και τα μειονεκτήματά τους.

4.1 Μέθοδοι Κλίσης - *Lyapunov*

Στην παρούσα ενότητα θα σκιαγραφήσουμε, με την βοήθεια απλών περιπτώσεων, τις βασικές τεχνικές σχηματισμού αναδρομικών αλγορίθμων και θα μελετήσουμε τις ιδιότητές τους.

4.1.1 Η μέθοδος της κλίσης

Θα αναλύσουμε την μέθοδο της κλίσης, (gradient) για την περίπτωση βαθμωτών συστημάτων, που περιγράφονται από την βαθμωτή αλγεβρική εξίσωση:

$$y(t) = \theta^\star u(t) \tag{4.1.1}$$

όπου $y \in \Re$ η έξοδος, $u \in \Re$ η είσοδος και $\theta^\star$ είναι μια άγνωστη σταθερή παράμετρος του συστήματος. Όπως είδαμε στο Κεφάλαιο 2, η (4.1.1) αποτελεί ειδική περίπτωση της γραμμικής παραμετροποίησης, η οποία εκφράζει και αρκετά γενικές κατηγορίες ακόμα και μη-γραμμικών συστημάτων.

Επιστρέφοντας στην (4.1.1), υποθέτουμε ότι τόσο η έξοδος όσο και η είσοδος είναι μετρήσιμα μεγέθη και επιπλέον η είσοδος είναι φραγμένη συνάρτηση του χρόνου t με κάποιο άγνωστο άνω φράγμα. Μ' άλλα λόγια $u \in L_\infty$. Στόχος μας είναι η εύρεση μιας εκτίμησης $\hat{\theta}$ του $\theta^\star$ για κάθε χρόνο t.

Θα μπορούσε να ισχυριστεί κανείς, παρατηρώντας την (4.1.1), ότι αν $u(t) \neq 0, \quad \forall t \geq 0$ τότε:

$$\hat{\theta} = \frac{y(t)}{u(t)} \tag{4.1.2}$$

Όμως η λύση (4.1.2) είναι ανεπιθύμητη ακόμα και απουσία θορύβου στο σύστημά μας, διότι η είσοδος $u(t)$ μπορεί να παίρνει τιμές πολύ κοντά στο μηδέν κάποιες χρονικές στιγμές, δημιουργώντας αριθμητικά προβλήματα (αίσθηση διαίρεσης με το μηδέν). Βέβαια, παρουσία θορύβου η εκτίμηση $\hat{\theta}$ θα αποκλίνει σημαντικά από το $\theta^\star$ όπως άλλωστε είδαμε και στο Κεφάλαιο 3 στην συζήτηση για την off-line έκδοση της μεθόδου των ελαχίστων τετραγώνων.

Στο κεφάλαιο αυτό επιθυμούμε να δημιουργήσουμε ένα αναδρομικό αλγόριθμο προσδιορισμού του $\hat{\theta}$. Θεωρούμε το σύστημα αναγνώρισης (identifier)

$$\hat{y}(t) = \hat{\theta}(t)u(t) \tag{4.1.3}$$

όπου η έξοδος $\hat{y}(t)$ αποτελεί εκτίμηση της εξόδου $y(t)$ του πραγματικού συστήματος (4.1.1). Από τις (4.1.1) και (4.1.3) σχηματίζεται το σφάλμα αναγνώρισης:

$$e = y - \hat{y} = y - \hat{\theta}u = \left(\theta^\star - \hat{\theta}\right) u \tag{4.1.4}$$

Αν ορίσουμε το παραμετρικό σφάλμα ως:

$$\tilde{\theta} = \hat{\theta} - \theta^\star$$

η (4.1.4) γράφεται:

$$e = -\tilde{\theta}u \tag{4.1.5}$$

από την οποία και φαίνεται η εξάρτηση του σφάλματος αναγνώρισης e από το παραμετρικό σφάλμα $\tilde{\theta}$.

Η μέθοδος της κλίσης στηρίζεται για την εύρεση της αναδρομικής εκτίμησης $\hat{\theta}$ του $\theta^\star$ στην ελαχιστοποίηση ως προς $\hat{\theta}$ κατάλληλα ορισμένης συνάρτησης κόστους του e. Μια τυπική συνάρτηση κόστους είναι:

$$K(\hat{\theta}) = \frac{e^2}{2} = \frac{(y - \hat{\theta}u)^2}{2} \tag{4.1.6}$$

Θέλουμε λοιπόν

$$\arg\min_{\hat{\theta}} K(\hat{\theta})$$

Επειδή η $K(\hat{\theta})$ όπως ορίστηκε είναι κυρτή $\forall t \geq 0$, κάθε τοπικό ελάχιστο της $K(\hat{\theta})$ θα είναι και ολικό και θα ικανοποιεί την εξίσωση:

$$\nabla K(\hat{\theta})|_{\hat{\theta}=\theta^\star} = 0 \tag{4.1.7}$$

Από την (4.1.6) προκύπτει:

$$\nabla K(\hat{\theta}) = -(y - \hat{\theta}u)u \tag{4.1.8}$$

Σύμφωνα με την μέθοδο της κλίσης:

$$\dot{\hat{\theta}} = -\gamma \nabla K(\hat{\theta}) = \gamma(y - \hat{\theta}u)u = \gamma e u, \quad \hat{\theta}(0) = \theta_0 \tag{4.1.9}$$

όπου $\gamma > 0$ μια σταθερά και $\hat{\theta}(0)$ η αρχική τιμή του $\hat{\theta}$.

Παρατηρείστε ότι το πραγματικό σύστημα (4.1.1) είναι ευσταθές υπό την έννοια της φραγμένης εισόδου - φραγμένης εξόδου. Επειδή δεν χρησιμοποιείται ανάδραση και το πραγματικό σύστημα δεν διεγείρεται από άλλη είσοδο εκτός του u, το πρόβλημα της ευστάθειάς του είναι εξασφαλισμένο. Δεν ισχύει όμως το ίδιο και για το σύστημα αναγνώρισης (4.1.3). Εδώ το γεγονός ότι το $\hat{\theta}(t)$ παράγεται μέσω της (4.1.9) μπορεί να οδηγήσει το (4.1.3) σε αστάθεια. Σε ότι ακολουθεί, θα μελετήσουμε την ευστάθεια του συστήματος (4.1.3), (4.1.9).

Μέθοδος κλίσης - ευστάθεια

Αν παραγωγίσουμε το παραμετρικό σφάλμα $\tilde{\theta}$ ως προς τον χρόνο προκύπτει λόγω της (4.1.9) και από το ότι το $\theta^\star$ είναι σταθερό άρα $\dot{\theta}^\star = 0$ ότι:

$$\dot{\tilde{\theta}} = \dot{\hat{\theta}} - \dot{\theta}^\star = \gamma e u \tag{4.1.10}$$

Χρησιμοποιώντας την (4.1.5), η (4.1.10) γίνεται:

$$\dot{\tilde{\theta}} = -\gamma \tilde{\theta} u^2, \quad \tilde{\theta}(0) = \hat{\theta}(0) - \theta^\star \tag{4.1.11}$$

Παρατηρείστε ότι η (4.1.11) δεν είναι υλοποιήσιμη, δίοτι το $\tilde{\theta}(0)$ είναι άγνωστο και θα χρησιμοποιηθεί μόνο για ανάλυση.

Η ανάλυση της ευστάθειας του συστήματος αναγνώρισης ανάγεται στην ανάλυση ευστάθειας της (4.1.11). Για τον σκοπό αυτό θεωρούμε την συνάρτηση `Lyapunov`:

$$V = \frac{\tilde{\theta}^2}{2} \geq 0 \tag{4.1.12}$$

Η παράγωγος ως προς τον χρόνο της V κατά μήκος της λύσης της διαφορικής εξίσωσης (4.1.11) είναι:

$$\dot{V} = \tilde{\theta}\dot{\tilde{\theta}} = -\gamma u^2 \tilde{\theta}^2 = -\gamma e^2 \leq 0 \tag{4.1.13}$$

Από την (4.1.13) συμπεραίνουμε ότι το παραμετρικό σφάλμα $\tilde{\theta}$ είναι ομοιόμορφα φραγμένο ή $\tilde{\theta} \in L_\infty$. Επειδή $\tilde{\theta} = \hat{\theta} - \theta^\star$ και $\theta^\star$ σταθερό, έχουμε και $\hat{\theta} \in L_\infty$. Παρατηρήστε ότι η V ως μεγαλύτερη ή ίση του μηδενός είναι φραγμένη κάτω από το μηδέν. Επιπλέον, είναι και φθίνουσα διότι $\dot{V} \leq 0$. Επομένως, το $\lim_{t\to\infty} V(\tilde{\theta}(t)) = V_\infty$ υπάρχει. Ολοκληρώνοντας και τα δύο μέρη της (4.1.13) βρίσκουμε:

$$\int_0^\infty e^2 d\tau = -\frac{1}{\gamma}\int_0^\infty \dot{V}(\tau)d\tau = -\frac{1}{\gamma}\left[V_\infty - V(0)\right] \tag{4.1.14}$$

με $V(0) = \frac{\tilde{\theta}^2(0)}{2}$. Από την (4.1.14) προκύπτει ότι $e \in L_2$. Συνεχίζοντας έχουμε ότι $\hat{y} = \hat{\theta}u$. Επειδή $\hat{\theta}, u \in L_\infty$, θα είναι και $\hat{y} \in L_\infty$. Επομένως, $e = y - \hat{y} \in L_\infty$. Από την (4.1.9) βρίσκουμε ότι $\dot{\hat{\theta}} \in L_\infty$ ως γινόμενο ομοιόμορφα φραγμένων συναρτήσεων. Από την (4.1.5) προκύπτει:

$$\dot{e} = -\dot{\tilde{\theta}}u - \tilde{\theta}\dot{u} \tag{4.1.15}$$

Αν υποθέσουμε επιπλέον ότι $\dot{u} \in L_\infty$, καταλήγουμε ότι $\dot{e} \in L_\infty$. Συνεπώς, $e \in L_2 \bigcap L_\infty$ και $\dot{e} \in L_\infty$, άρα εκμεταλλευόμενοι το Λήμμα του Barbalat βρίσκουμε ότι $\lim_{t\to\infty} e(t) = 0$. Επειδή $\dot{\hat{\theta}} = -\gamma e u$ θα έχουμε και $\lim_{t\to\infty} \dot{\hat{\theta}} = 0$ ως γινόμενο συνάρτησης που έχει όριο το μηδέν, με ομοιόμορφα φραγμένη.

Συμπέρασμα 4.1.1 Για εισόδους που ικανοποιούν $u, \dot{u} \in L_\infty$, ο αναδρομικός νόμος μεταβολής των εκτιμώμενων παραμέτρων $\dot{\hat{\theta}} = -\gamma e u$ εξασφαλίζει ότι η εκτιμώμενη έξοδος $\hat{y}(t)$ του συστήματος αναγνώρισης $\hat{y} = \hat{\theta}u$ θα συγκλίνει ασυμπτωτικά στην έξοδο $y(t)$ του πραγματικού συστήματος $y(t) = \theta^\star u(t)$ και ο ρυθμός μεταβολής των παραμέτρων $\dot{\hat{\theta}}(t)$ θα μειώνεται με τον χρόνο και θα συγκλίνει ασυμπτωτικά στο μηδέν.

Στο Συμπέρασμα 4.1.1 δεν αναφέρουμε τίποτα σχετικά με την σύγκλιση της εκτιμώμενης παραμέτρου $\hat{\theta}(t)$ στην πραγματική παράμετρο $\theta^\star$. Μια επιπόλαιη ματιά στο αποτέλεσμα $\lim_{t\to\infty} \dot{\hat{\theta}}(t) = 0$ θα οδηγούσε στο συμπέρασμα ότι $\lim_{t\to\infty} \hat{\theta}(t) = \bar{\theta}$ όπου $\bar{\theta}$ μια σταθερά. Κάτι τέτοιο όμως δεν ισχύει. Για να γίνει ξεκάθαρο, θεωρείστε την περίπτωση όπου $\hat{\theta}(t) = \cos(\ln t)$. Η παράγωγος είναι $\dot{\hat{\theta}}(t) = \frac{1}{t}\sin(\ln t)$. Προφανώς $\lim_{t\to\infty} \dot{\hat{\theta}}(t) = 0$ ως γινόμενο συνάρτησης με όριο το μηδέν ($\lim_{t\to\infty} \frac{1}{t} = 0$), με ομοιόμορφα φραγμένη. Όμως, $\lim_{t\to\infty} \hat{\theta}(t) = \lim_{t\to\infty} \cos(\ln t)$ δεν υπάρχει. Δείξαμε όμως ότι $\lim_{t\to\infty} V(t) = V_\infty$ υπάρχει. Συνεπώς, $\lim_{t\to\infty} \frac{\tilde{\theta}^2(t)}{2} = V_\infty$ ή διαφορετικά, $\lim_{t\to\infty} \tilde{\theta}(t) = \pm\sqrt{2V_\infty}$. Επομένως, $\lim_{t\to\infty} \hat{\theta}(t) = \pm\sqrt{2V_\infty} + \theta^\star = \bar{\theta}$ σταθερό. Αλλά ποια είναι η σχέση του $\theta^\star$ με το $\bar{\theta}$; Στην απλή περίπτωση που μελετάμε μπορούμε να λύσουμε αναλυτικά την διαφορική εξίσωση (4.1.11) για να βρούμε:

$$\tilde{\theta}(t) = \left[e^{-\gamma\int_0^t u^2(\tau)d\tau}\right]\tilde{\theta}(0) \tag{4.1.16}$$

Στην (4.1.16) με e συμβολίζουμε την βάση των νεπέριων λογαρίθμων ($e = 2.718281$). Από την (4.1.16) είναι προφανές ότι για να συγκλίνει το παραμετρικό σφάλμα στο μηδέν, θα πρέπει το $\int_0^t u^2(\tau)d\tau$ να είναι γνήσια θετικό $\forall t \geq 0$. Αποδεικνύεται ότι ικανή και αναγκαία συνθήκη για να ισχύει $\lim_{t\to\infty} \hat{\theta}(t) = \theta^\star$ εκθετικά, είναι η είσοδος $u(t)$ να ικανοποιεί:

$$\int_t^{t+T_0} u^2(\tau)d\tau \geq \alpha_0 T_0 \tag{4.1.17}$$

$\forall t \geq 0$ και για κάποια $\alpha_0, T_0 > 0$. Μπορεί εύκολα να διαπιστώσει κανείς ότι τα σήματα εισόδου $u(t) = 0$ ή $u(t) = e^{-t}, \quad t \geq 0$ δεν δίνουν $\lim_{t\to\infty} \tilde{\theta}(t) = 0$. Αντίθετα, για την μοναδιαία βηματική είσοδος $u(t) = 1, \quad t \geq 0$, το παραμετρικό σφάλμα $\tilde{\theta}(t)$ θα συγκλίνει εκθετικά στο μηδέν. Η (4.1.17) ονομάζεται *συνθήκη επιμένουσας διέγερσης* (persistance of excitation condition). Από τις (4.1.16) και (4.1.17) προκύπτει ότι ο ρυθμός της εκθετικής σύγκλισης του $\tilde{\theta}(t)$ στο μηδέν, ελέγχεται από τον συντελεστή γ, καθώς και από το επίπεδο διέγερσης α_0. Αυξάνοντας την τιμή του γ επιταχύνουμε την σύγκλιση του $\hat{\theta}(t)$ στο $\theta^\star$. Πολύ μεγάλο γ όμως καθιστά την (4.1.9) 'άκαμπτη' (stiff) και επομένως δυσκολότερα αριθμητικά επιλύσιμη.

Η ίδια ανάλυση που ακολουθήθηκε παραπάνω, μπορεί να εφαρμοστεί και σε πολυ-διάστατα μοντέλα της μορφής:

$$y = \theta^{\star T}\phi, \quad y \in \Re,\ \theta^\star, \phi \in \Re^n \tag{4.1.18}$$

Στην περίπτωση n-διάστατων διανυσματικών σημάτων $\phi(t)$, η συνθήκη επιμένουσας διέγερσης ορίζεται ως εξής:

Ορισμός 4.1.1 Συνθήκη Επιμένουσας Διέγερσης (ΣΕΔ). Ένα τμηματικά συνεχές διανυσματικό σήμα $\phi(t) : \Re_+ \to \Re^n$ θα λέγεται ότι ικανοποιεί την ΣΕΔ με επίπεδο διέγερσης $\alpha_0 > 0$, αν υπάρχουν σταθερές $\alpha_1, T_0 > 0$ τέτοιες ώστε:

$$\alpha_1 I \geq \frac{1}{T_0}\int_t^{t+T_0} \phi(\tau)\phi^T(\tau)d\tau \geq \alpha_0 I, \quad \forall t \geq 0$$

με I τον μοναδιαίο πίνακα.

4.1.2 Μέθοδος σχεδίασης κατά *Lyapunov*

Θεωρείστε το πρώτης τάξης ΓΧΑ σύστημα:

$$\dot{x} = -\theta_1^\star x + \theta_2^\star u, \quad x(0) = x_0 \tag{4.1.19}$$

όπου οι παράμετροι $\theta_1^\star$, $theta_2^\star$ είναι σταθερές αλλά άγνωστες και τόσο η είσοδος u, όσο και η κατάσταση x είναι μετρήσιμες. Επιπλέον υποθέστε ότι $\theta_1^\star > 0$ και $u \in L_\infty$. Τότε η (4.1.19) θα δώσει ομοιόμορφα φραγμένη έξοδο $x \in L_\infty$. Στόχος μας είναι η δημιουργία αναδρομικών σχέσεων για την εκτίμηση των $\theta_1^\star$, $\theta_2^\star$. Στην παρούσα ενότητα θα χρησιμοποιήσουμε την μέθοδο σχεδίασης κατά Lyapunov.

Πριν προχωρήσουμε στην παρουσίαση της μεθόδου, σκόπιμο είναι να παραθέσουμε τις δύο γενικές τοπολογίες αναγνώρισης που συναντώνται συχνά στην βιβλιογραφία. Η πρώτη, χρησιμοποιεί

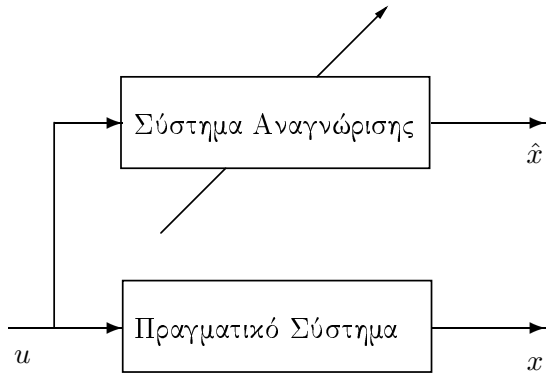

Σχήμα 4.1: Διάγραμμα βαθμίδων της παράλληλης τοπολογίας συστήματος αναγνώρισης.

αποκλειστικά σήματα που παράγονται από το σύστημα αναγνώρισης και ονομάζεται *παράλληλη (Π) δομή* (parallel configuration). Περιγράφεται από διαφορική εξίσωση της μορφής:

$$\dot{\hat{x}} = -\hat{\theta}_1\hat{x} + \hat{\theta}_2 u, \quad \hat{x}(0) = \hat{x}_0 \tag{4.1.20}$$

Η δεύτερη, χρησιμοποιεί σήματα που παράγονται τόσο από το σύστημα αναγνώρισης, όσο και από το πραγματικό σύστημα, και ονομάζεται *μεικτή (Μ) δομή*. Στην διεθνή βιβλιογραφία έχει καθιερωθεί με τον όρο series - parallel configuration. Περιγράφεται από διαφορική εξίσωση της μορφής:

$$\dot{\hat{x}} = -\hat{\theta}_1\hat{x} + \hat{\theta}_2 u - \theta_m(x - \hat{x}), \quad \hat{x}(0) = \hat{x}_0 \tag{4.1.21}$$

Τα $\hat{\theta}_1$, $\hat{\theta}_2$ που εμφανίζονται και στις δύο τοπολογίες αποτελούν εκτιμήσεις των $\theta_1^\star$ και $\theta_2^\star$ αντίστοιχα. Τέλος, το θ_m είναι μια θετική πραγματική σταθερά. Η ονομασία των δύο τοπολογιών γίνεται προφανής αν χρησιμοποιήσουμε διαγράμματα βαθμίδων (block diagrams). Το διάγραμμα βαθμίδων για την παράλληλη τοπολογία δίνεται στο Σχ. 4.1, ενώ για την μεικτή στο Σχ. 4.2. Τόσο στο Σχ. 4.1, όσο και στο Σχ. 4.2, το βέλος που τέμνει την βαθμίδα του συστήματος αναγνώρισης δηλώνει την μεταβολή των παραμέτρων $\hat{\theta}_1$, $\hat{\theta}_2$ που συντελείται εντός αυτής.

Παρατηρήστε ότι το πραγματικό σύστημα (4.1.19) μπορεί να γραφεί στην μορφή:

$$\dot{x} = -\theta_1^\star x + \theta_2^\star u - \theta_m x + \theta_m x$$

ή

$$\dot{x} + \theta_m x = (\theta_m - \theta_1^\star)x + \theta_2^\star u \tag{4.1.22}$$

Η (4.1.22) γράφεται ισοδύναμα:

$$\begin{aligned} x &= \frac{1}{s+\theta_m}\left[(\theta_m - \theta_1^\star)x + \theta_2^\star u\right] \\ &= \theta^{\star T}\phi \end{aligned} \tag{4.1.23}$$

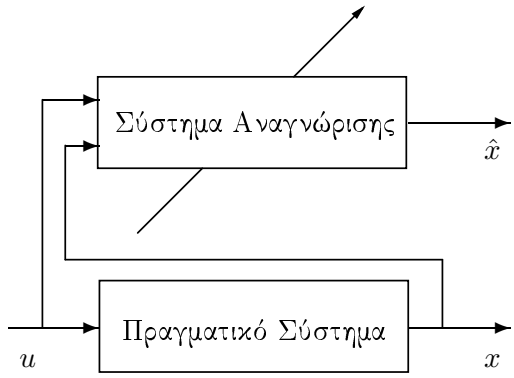

Σχήμα 4.2: Διάγραμμα βαθμίδων της μεικτής τοπολογίας συστήματος αναγνώρισης.

όπου στην (4.1.23) $\theta^\star = [\theta_m - \theta_1^\star \ \theta_2^\star]^T$ και $\phi = \left[\frac{x}{s+\theta_m} \ \frac{u}{s+\theta_m}\right]^T$. Η (4.1.23) αποτελεί την γραμμικά παραμετροποιημένη αλγεβρική αναπαράσταση του πραγματικού συστήματος, τις παραμέτρους του οποίου στην προηγούμενη ενότητα τις εκτιμήσαμε κάνοντας χρήση της μεθόδου της κλίσης.

Ανάλυση της μεθόδου σχεδίασης κατά *Lyapunov*

Η μέθοδος θα παρουσιαστεί σε σχέση με μοντέλα πραγματικών συστημάτων της μορφής (4.1.19) κανοντας χρήση της (Π) ή της (Μ) δομής συστήματος αναγνώρισης. Πιο συγκεκριμένα, ορίζουμε το σφάλμα αναγνώρισης ως $e = x - \hat{x}$. Παραγωγίζοντας ως προς τον χρόνο το e ακολουθώντας την λύση των (4.1.19) και (4.1.20) προκύπτει η διαφορική εξίσωση του σφάλματος αναγνώρισης όταν χρησιμοποιείται η (Π) δομή συστήματος αναγνώρισης:

$$\begin{aligned} \dot{e} &= -\theta_1^\star x + \theta_2^\star u + \hat{\theta}_1 \hat{x} - \hat{\theta}_2 u \\ &= -\theta_1^\star x + \hat{\theta}_1 \hat{x} - (\hat{\theta}_2 - \theta_2^\star) u \end{aligned} \tag{4.1.24}$$

Αν προσθαφαιρέσουμε τον παράγοντα $\theta_1^\star \hat{x}$ στην (4.1.24) βρίσκουμε:

$$\dot{e} = -\theta_1^\star (x - \hat{x}) + (\hat{\theta}_1 - \theta_1^\star)\hat{x} - (\hat{\theta}_2 - \theta_2^\star) u \tag{4.1.25}$$

Αν ορίσουμε τα παραμετρικά σφάλματα $\tilde{\theta}_1 = \hat{\theta}_1 - \theta_1^\star$ και $\tilde{\theta}_2 = \hat{\theta}_2 - \theta_2^\star$ η (4.1.25) γράφεται:

$$\dot{e} = -\theta_1^\star e + \tilde{\theta}_1 \hat{x} - \tilde{\theta}_2 u \tag{4.1.26}$$

Εργαζόμενοι ομοίως με την διαφορά ότι τώρα θα χρησιμοποιήσουμε την (4.1.21) αντί της (4.1.20), προκύπτει η διαφορική εξίσωση του σφάλματος αναγνώρισης για την (Μ) δομή συστήματος αναγνώρισης:

$$\dot{e} = -\theta_m e + \tilde{\theta}_1 x - \tilde{\theta}_2 u \tag{4.1.27}$$

Ας θεωρήσουμε αρχικά την περίπτωση της διαφορικής εξίσωσης σφάλματος (4.1.27) που προκύπτει λαμβάνοντας την (M) δομή για το σύστημα αναγνώρισης και την συνάρτηση Lyapunov:

$$V = \frac{1}{2}e^2 + \frac{1}{2}\tilde{\theta}_1^2 + \frac{1}{2}\tilde{\theta}_2^2 \tag{4.1.28}$$

Είναι προφανές ότι $V > 0 \quad \forall e, \tilde{\theta}_1, \tilde{\theta}_2 \in \Re$ και $V = 0$ μόνο όταν $(e\ \tilde{\theta}_1\ \tilde{\theta}_2) = (0\ 0\ 0)$. Επιπλέον η V είναι ακτινικά μη-φραγμένη (radially unbounded), που σημαίνει ότι $\lim_{e,\tilde{\theta}_1,\tilde{\theta}_2\to\infty} V = \infty$. Η χρονική παράγωγος της V κατά μήκος της λύσης της (4.1.27) είναι:

$$\begin{aligned} \dot{V} &= e\dot{e} + \tilde{\theta}_1\dot{\tilde{\theta}}_1 + \tilde{\theta}_2\dot{\tilde{\theta}}_2 \\ &= -\theta_m e^2 + \tilde{\theta}_1 ex - \tilde{\theta}_2 eu + \tilde{\theta}_1\dot{\tilde{\theta}}_1 + \tilde{\theta}_2\dot{\tilde{\theta}}_2 \end{aligned} \tag{4.1.29}$$

Από τον ορισμό των παραμετρικών σφαλμάτων έχουμε ότι $\dot{\tilde{\theta}}_1 = \dot{\hat{\theta}}_1$ και $\dot{\tilde{\theta}}_2 = \dot{\hat{\theta}}_2$. Επομένως, η (4.1.29) γράφεται:

$$\dot{V} = -\theta_m e^2 + \tilde{\theta}_1 ex - \tilde{\theta}_2 eu + \tilde{\theta}_1\dot{\hat{\theta}}_1 + \tilde{\theta}_2\dot{\hat{\theta}}_2 \tag{4.1.30}$$

Αν επιλέξουμε:

$$\dot{\hat{\theta}}_1 = -ex \tag{4.1.31}$$

$$\dot{\hat{\theta}}_2 = eu \tag{4.1.32}$$

η (4.1.30) γίνεται:

$$\dot{V} = -\theta_m e^2 \leq 0 \tag{4.1.33}$$

Επομένως, $e, \tilde{\theta}_1, \tilde{\theta}_2 \in L_\infty$. Επιπλέον, $V \geq 0$ και V φθίνουσα συνάρτηση του χρόνου μια και $\dot{V} \leq 0$. Επομένως, το $\lim_{t\to\infty} V = V_\infty$ υπάρχει. Ολοκληρώνοντας και τα δύο μέρη της (4.1.33) από 0 έως ∞ προκύπτει:

$$\theta_m \int_0^\infty e^2 d\tau = -\int_0^\infty \dot{V} d\tau = -[V_\infty - V(0)] \tag{4.1.34}$$

Συνεπώς, $e \in L_2$. Υποθέσαμε στην αρχή της ενότητας ότι $u \in L_\infty$ και μας προέκυψε $x \in L_\infty$. Επειδή $e = x - \hat{x} \in L_\infty$, συνεπάγεται ότι και $\hat{x} \in L_\infty$. Από την (4.1.27) συμπεραίνουμε ότι $\dot{e} \in L_\infty$ μια και είναι άθροισμα ομοιόμορφα φραγμένων σημάτων. Συνεπώς, κάνοντας χρήση του Λήμματος του Barbalat, επειδή $e \in L_2 \bigcap L_\infty$ και $\dot{e} \in L_\infty$ συνεπάγεται ότι $\lim_{t\to\infty} e(t) = 0$. Επιλπέον, $\lim_{t\to\infty} \dot{\hat{\theta}}_1(t) = \lim_{t\to\infty} \dot{\hat{\theta}}_2(t) = 0$ ως γινόμενο ομοιόμορφα φραγμένης συνάρτησης με συνάρτηση που έχει όριο το μηδέν.

Συμπέρασμα 4.1.2 Για ομοιόμορφα φραγμένες εισόδους $u \in L_\infty$, ο αναδρομικός νόμος μεταβολής των εκτιμώμενων παραμέτρων $\dot{\hat{\theta}}_1 = -ex$ και $\dot{\hat{\theta}}_2 = eu$ εξασφαλίζει ότι η εκτιμώμενη έξοδος $\hat{x}$ της μεικτής δομής συστήματος αναγνώρισης θα συγκλίνει στην έξοδο x του πραγματικού συστήματος και ο ρυθμός μεταβολής των παραμέτρων $\dot{\hat{\theta}}_1$, $\dot{\hat{\theta}}_2$ θα μειώνεται με τον χρόνο και θα συγκλίνει ασυμπτωτικά στο μηδέν.

Όπως και στην περίπτωση της μεθόδου κλίσης, το γεγονός ότι $\lim_{t\to\infty} e(t) = 0$ και $\lim_{t\to\infty} \dot{\hat{\theta}}_1(t) = \lim_{t\to\infty} \dot{\hat{\theta}}_2(t) = 0$ δεν συνεπάγεται κατ' ανάγκη ότι τα $\tilde{\theta}_1$, $\tilde{\theta}_2$ θα συγκλίνουν σε μια σταθερή τιμή. Πράγματι είδαμε ότι $\lim_{t\to\infty} V(t) = V_\infty$ υπάρχει. Επομένως, $\lim_{t\to\infty}[e^2(t) + \tilde{\theta}_1^2(t) + \tilde{\theta}_2^2] = 2V_\infty$ ή λόγω του ότι $\lim_{t\to\infty} e(t) = 0$, $\lim_{t\to\infty}[\tilde{\theta}_1^2(t) + \tilde{\theta}_2^2(t)] = 2V_\infty$. Όμως το άθροισμα $\tilde{\theta}_1^2(t) + \tilde{\theta}_2^2(t)$ μπορεί να έχει όριο στο άπειρο χωρίς να ισχύει το ίδιο και για τα $\tilde{\theta}_1(t)$, $\tilde{\theta}_2(t)$. Θεωρείστε για παράδειγμα την περίπτωση:

$$\tilde{\theta}_1(t) = \sqrt{2V_\infty}\cos t, \quad \tilde{\theta}_1(t) = \sqrt{2V_\infty}\sin t$$

Προφανώς, $\tilde{\theta}_1^2(t) + \tilde{\theta}_2^2(t) = 2V_\infty, \quad \forall t \geq 0$. Όμως τόσο το $\tilde{\theta}_1(t)$ όσο και το $\tilde{\theta}_2(t)$ δεν έχουν όριο στο άπειρο.

Είναι γεγονός ότι μόλις δοθεί η διαφορική εξίσωση σφάλματος, δεν υπάρχει γενικός αλγόριθμος προσδιορισμού της συνάρτησης Lyapunov. Θα μπορούσε λοιπόν να σκεφτεί κανείς ότι ο λόγος που δεν είμαστε σε θέση να εγγυηθούμε την ασυμπτωτική σύγκλιση των παραμετρικών σφαλμάτων στο μηδέν είναι η μη σωστή επιλογή της συνάρτησης Lyapunov και κατ' επέκταση ο αναδρομικός νόμος εκτίμησης των παραμέτρων του πραγματικού συστήματος. Ο παραπάνω συλλογισμός δεν είναι αληθής. Το πραγματικό αίτιο της μη επίτευξης του στόχου μας είναι ότι δεν έχουμε θέσει κάποιον περιορισμό στην είσοδο επιπλέον του $u \in L_\infty$. Θεωρείστε για παράδειγμα την περίπτωση $u = 0, \quad \forall t \geq 0$. Η συγκεκριμένη είσοδος ικανοποιεί την υπόθεσή μας (η $u = 0$ είναι ομοιόμορφα φραγμένη), όμως είναι προφανές ότι αν και $x(0) = 0$ θα πάρουμε $x(t) = 0, \quad \forall t \geq 0$. Οποιαδήποτε επιλογή συνάρτησης Lyapunov και νόμων εκτίμησης παραμέτρων, δεν είναι ικανή να δώσει σωστή εκτίμηση των άγνωστων παραμέτρων του πραγματικού συστήματος. Όπως και στην προηγούμενη ενότητα, η είσοδος πρέπει να ικανοποιεί μια ΣΕΔ προκειμένου να ολοκληρωθεί η επίτευξη του στόχου μας.

Ακολουθώντας τα ίδια ακριβώς βήματα, καταλήγουμε στο παρακάτω συμπέρασμα για την περίπτωση χρήσης της παράλληλης δομής συστήματος αναγνώρισης.

Συμπέρασμα 4.1.3 Για ομοιόμορφα φραγμένες εισόδους $u \in L_\infty$, ο αναδρομικός νόμος μεταβολής των εκτιμώμενων παραμέτρων $\dot{\hat{\theta}}_1 = -e\hat{x}$ και $\dot{\hat{\theta}}_2 = eu$, εξασφαλίζει ότι η εκτιμώμενη έξοδος της παράλληλης δομής συστήματος αναγνώρισης θα συγκλίνει στην έξοδο x του πραγματικού συστήματος και ο ρυθμός μεταβολής των παραμέτρων $\dot{\hat{\theta}}_1, \dot{\hat{\theta}}_2$ θα μειώνεται με τον χρόνο και θα συγκλίνει ασυμπτωτικά στο μηδέν.

Υπάρχει άραγε κάποιος τομέας στον οποίο να υπερτερεί η χρήση της (Π) δομής σε σχέση με την (Μ) δομή, ή είναι απόλυτα ισοδύναμες; Η απάντηση θα δοθεί παρατηρώντας τους νόμους που δίνουν την εκτίμηση $\hat{\theta}_1(t)$. Πράγματι:

$$\begin{aligned} \dot{\hat{\theta}}_1 &= -e\hat{x} = -(x-\hat{x})\hat{x} = \hat{x}^2 - x\hat{x} \quad \text{(Π δομή)} \\ \dot{\hat{\theta}}_1 &= -ex = -(x-\hat{x})x = x^2 - x\hat{x} \quad \text{(Μ δομή)} \end{aligned}$$

Αν υποθέσουμε ότι η έξοδος του πραγματικού συστήματος έχει διαβρωθεί από προσθετικό θόρυβο $\eta(t)$, αν δηλαδή αντί του x στις παραπάνω εξισώσεις βάλουμε το $x + \eta$, θα παρατηρήσουμε ότι στην

Μ δομή η εκτίμηση $\hat{\theta}_1$ θα εξαρτάται τόσο από το $\eta(t)^2$ όσο και από το $\eta(t)$. Αντίθετα στην Π δομή μόνο από το $\eta(t)$. Συνεπώς, η Μ δομή είναι πιο ευαίσθητη στην παρουσία θορύβου σε σχέση με την Π δομή.

Εφαρμογή της μεθόδου *Lyapunov* σε μη-γραμμικά συστήματα

Θεωρείστε το μη-γραμμικό σύστημα:

$$\dot{x} = \theta_1^\star f(x) + \theta_2^\star g(x)u \tag{4.1.35}$$

όπου $x, u \in \Re$ και $x, u \in L_\infty$. Όπως και πριν επιθυμούμε την εύρεση αναδρομικών νόμων εκτίμησης των σταθερών αλλά άγνωστων παραμέτρων $\theta_1^\star$, $\theta_2^\star$. Επιλέγουμε την μεικτή δομή συστήματος αναγνώρισης:

$$\dot{\hat{x}} = \hat{\theta}_1 f(x) + \hat{\theta}_2 g(x)u + a_m(x - \hat{x}) \tag{4.1.36}$$

Στην (4.1.36), $\hat{\theta}_1, \hat{\theta}_2$ είναι οι εκτιμήσεις των $\theta_1^\star$, $\theta_2^\star$ αντίστοιχα και $a_m > 0$. Το σφάλμα αναγνώρισης ορίζεται ως $e = x - \hat{x}$. Παραγωγίζοντας ως προς χρόνο το e κατά μήκος των λύσεων των (4.1.35), (4.1.36) προκύπτει η διαφορική εξίσωση του σφάλματος:

$$\dot{e} = -a_m e - \tilde{\theta}_1 f(x) - \tilde{\theta}_2 g(x)u \tag{4.1.37}$$

όπου $\tilde{\theta}_1 = \hat{\theta}_1 - \theta_1^\star$ και $\tilde{\theta}_2 = \hat{\theta}_2 - \theta_2^\star$. Ορίζουμε την συνάρτηση `Lyapunov`:

$$V = \frac{1}{2}e^2 + \frac{1}{2}\tilde{\theta}_1^2 + \frac{1}{2}\tilde{\theta}_2^2 \tag{4.1.38}$$

Παραγωγίζοντας την V ως προς τον χρόνο βρίσκουμε:

$$\begin{aligned} \dot{V} &= e\dot{e} + \tilde{\theta}_1\dot{\hat{\theta}}_1 + \tilde{\theta}_2\dot{\hat{\theta}}_2 \\ &= -a_m e^2 - ef(x)\tilde{\theta}_1 - eg(x)u\tilde{\theta}_2 + \tilde{\theta}_1\dot{\hat{\theta}}_1 + \tilde{\theta}_2\dot{\hat{\theta}}_2 \end{aligned} \tag{4.1.39}$$

Επιλέγοντας:

$$\dot{\hat{\theta}}_1 = ef(x) \tag{4.1.40}$$

$$\dot{\hat{\theta}}_2 = eg(x)u \tag{4.1.41}$$

η (4.1.39) γίνεται:

$$\dot{V} = -a_m e^2 \leq 0 \tag{4.1.42}$$

Παρατηρούμε ότι η (4.1.42) είναι της ίδιας μορφής με την περίπτωση του γραμμικού συστήματος που αναλύσαμε προηγούμενα. Με την επιπλέον υπόθεση ότι $f(x), g(x) \in L_\infty$ για $x \in L_\infty$, τα αποτελέσματα του Συμπεράσματος 4.1.2 εξακολουθούν να ισχύουν.

Συστήματα μεγαλύτερης διάστασης

Θεωρείστε το ΓΧΑ σύστημα:

$$\dot{x} = Ax + Bu \tag{4.1.43}$$

όπου τόσο η κατάσταση $x \in \Re^n$ όσο και η είσοδος $u \in \Re^m$ είναι μετρήσιμα μεγέθη. Οι πίνακες $A \in \Re^{n\times n}$ και $B \in \Re^{n\times m}$ είναι σταθεροί αλλά άγνωστοι. Επιπλέον, ο A είναι αρνητικά ημιορισμένος και $u \in L_\infty$. Συνεπώς και $x \in L_\infty$. Για την ανάλυση θα χρησιμοποιήσουμε την Π δομή συστήματος αναγνώρισης. Άρα:

$$\dot{\hat{x}} = \hat{A}\hat{x} + \hat{B}u \tag{4.1.44}$$

όπου $\hat{x}$ είναι η εκτίμηση της εξόδου x του πραγματικού συστήματος και $\hat{A}, \hat{B}$ οι εκτιμήσεις των πινάκων A, B αντίστοιχα. Ορίζουμε το σφάλμα αναγνώρισης $e = x - \hat{x}$. Παραγωγίζοντας το e ως προς τον χρόνο προκύπτει η διαφορική εξίσωση του σφάλματος:

$$\dot{e} = Ax + Bu - \hat{A}\hat{x} - \hat{B}u \tag{4.1.45}$$

Αν προσθαφαιρέσουμε τον όρο $A\hat{x}$ η (4.1.45) γίνεται:

$$\dot{e} = A(x - \hat{x}) - (\hat{A} - A)\hat{x} - (\hat{B} - B)u \tag{4.1.46}$$

Ορίζουμε τα παραμετρικά σφάλματα $\tilde{A} = \hat{A} - A$, $\tilde{B} = \hat{B} - B$ και η (4.1.46) παίρνει την μορφή:

$$\dot{e} = Ae - \tilde{A}\hat{x} - \tilde{B}u \tag{4.1.47}$$

Θεωρείστε τώρα την συνάρτηση `Lyapunov`:

$$V = \frac{1}{2}e^T e + \frac{1}{2}tr\{\tilde{A}^T\tilde{A}\} + \frac{1}{2}tr\{\tilde{B}^T\tilde{B}\} \tag{4.1.48}$$

όπου με $tr\{.\}$ συμβολίζουμε το ίχνος (`trace`) ενός πίνακα. Αν παραγωγίσουμε την V ως προς τον χρόνο κατά μήκος της λύσης της (4.1.47) βρίσκουμε:

$$\begin{aligned} \dot{V} &= e^T\dot{e} + tr\{\tilde{A}^T\dot{\hat{A}}\} + tr\{\tilde{B}^T\dot{\hat{B}}\} \\ &= e^T Ae - e^T\tilde{A}\hat{x} - e^T\tilde{B}u + tr\{\tilde{A}^T\dot{\hat{A}}\} + tr\{\tilde{B}^T\dot{\hat{B}}\} \end{aligned} \tag{4.1.49}$$

Για το ίχνος ενός πίνακα ισχύουν οι παρακάτω σχέσεις τις οποίες και θα χρησιμοποιήσουμε στην (4.1.49):

$$\begin{aligned} tr\{\Gamma\Delta\} &= tr\{\Delta\Gamma\}, \qquad \Gamma, \Delta \in \Re^{n\times n} \\ tr\{\Gamma + \Delta\} &= tr\{\Gamma\} + tr\{\Delta\}, \qquad \Gamma, \Delta \in \Re^{n\times n} \\ tr\{yx^T\} &= x^T y, \qquad x, y \in \Re^{n\times 1} \end{aligned}$$

Έτσι λοιπόν:

$$\begin{aligned} e^T\tilde{A}\hat{x} &= tr\{\tilde{A}\hat{x}e^T\} \\ e^T\tilde{B}u &= tr\{\tilde{B}ue^T\} \end{aligned}$$

και η (4.1.49) γράφεται:

$$\dot{V} = e^T Ae + tr\{\tilde{A}\dot{\hat{A}} + \tilde{B}\dot{\hat{B}} - \tilde{A}\hat{x}e^T - \tilde{B}ue^T\} \tag{4.1.50}$$

Επιλέγοντας,

$$\dot{\hat{A}} = \hat{x}e^T \tag{4.1.51}$$

$$\dot{\hat{B}} = ue^T \tag{4.1.52}$$

η (4.1.50) γίνεται:

$$\dot{V} = e^T Ae \leq 0 \tag{4.1.53}$$

Ακολουθώντας τα ίδια βήματα με την πρωτοτάξια περίπτωση, μπορούμε να αποδείξουμε ότι $\hat{A}, \hat{B} \in L_\infty$, $e \in L_\infty \bigcap L_2$, $\dot{e} \in L_\infty$. Άρα $\lim_{t\to\infty} e(t) = \lim_{t\to\infty} \dot{\hat{A}}(t) = \lim_{t\to\infty} \dot{\hat{B}}(t) = 0$. Πάλι όμως δεν μπορούμε να εγγυηθούμε την σύγκλιση των παραμετρικών σφαλμάτων στο μηδέν, το οποίο επιτυγχάνεται εφόσον η είσοδος ικανοποιεί μια ΣΕΔ. Τότε η σύγκλιση θα είναι εκθετική.

4.2 Αναδρομική Μορφή της Μεθόδου των Ελαχίστων Τετραγώνων

Θεωρείστε όπως και στο Κεφάλαιο 3, το γραμμικά παραμετροποιημένο σύστημα:

$$y = \theta^{\star T}\phi \tag{4.2.1}$$

όπου η έξοδος $y \in \Re$, το διάνυσμα των άγνωστων αλλά σταθερών παραμέτρων $\theta^\star \in \Re^n$ και το διάνυσμα των οπισθοδρομητών $\phi \in \Re^n$. Τόσο η έξοδος όσο και το ϕ θεωρούνται μετρήσιμα μεγέθη. Επιπλέον, $y, \phi \in L_\infty$. Έστω το σύστημα αναγνώρισης:

$$\hat{y} = \hat{\theta}^T\phi \tag{4.2.2}$$

όπου $\hat{y} \in \Re$ η εκτιμώμενη έξοδος και $\hat{\theta} \in \Re^n$ το διάνυσμα των εκτιμώμενων παραμέτρων την χρονική στιγμή t. Το σφάλμα αναγνώρισης ορίζεται ως $\tilde{y} = y - \hat{y}$. Συνεπώς,

$$\tilde{y} = y - \hat{\theta}^T\phi \tag{4.2.3}$$

Έστω ότι θέλουμε να υπολογίσουμε την τιμή του $\hat{\theta}$ που ελαχιστοποιεί το κριτήριο:

$$K(\hat{\theta}) = \frac{1}{2}e^{-\beta t}(\hat{\theta}(t) - \hat{\theta}(0))^T Q_0(\hat{\theta}(t) - \hat{\theta}(0)) + \frac{1}{2}\int_0^t e^{-\beta(t-\tau)}[y(\tau) - \hat{\theta}(t)^T\phi(\tau)]^2 d\tau \tag{4.2.4}$$

όπου $Q_0 = Q_0^T > 0$ (θετικά ορισμένος πίνακας), $\beta \geq 0$ μια σταθερά. Το κριτήριο (4.2.4) αποτελεί προφανή γενίκευση αυτού που χρησιμοποιήθηκε στο Κεφάλαιο 3. Επειδή τα $y, \phi \in L_\infty$ η $K(\hat{\theta})$

είναι κυρτή συνάρτηση του $\hat{\theta}$ στο $\Re^n$, $\forall t \geq 0$. Επομένως, κάθε τοπικό ελάχιστο είναι και ολικό και ικανοποιεί:

$$\nabla K(\hat{\theta})|_{\hat{\theta}=\theta^\star} = 0, \quad \forall t \geq 0 \tag{4.2.5}$$

Από τις (4.2.4) και (4.2.5) προκύπτει:

$$\hat{\theta}(t) = P(t)\left[e^{-\beta t}Q_0\hat{\theta}(0) + \int_0^t e^{-\beta(t-\tau)}y(\tau)\phi(\tau)d\tau\right] \tag{4.2.6}$$

$$P(t) = \left[e^{-\beta t}Q_0 + \int_0^t e^{-\beta(t-\tau)}\phi(\tau)\phi^T(\tau)d\tau\right]^{-1} \tag{4.2.7}$$

Επειδή ο Q_0 και ο $\phi(\tau)\phi^T(\tau)$ είναι θετικά ορισμένοι, ο $P(t)$ υπάρχει $\forall t \geq 0$. Οι εξισώσεις (4.2.6) και (4.2.7) αποτελούν την γενικευμένη μη αναδρομική έκφραση της μεθόδου των ελαχίστων τετραγώνων. Απ΄ αυτή προκύπτει η αναδρομική έκφραση ως εξής:

Γνωρίζουμε ότι $PP^{-1} = I$ όπου I ο μοναδιαίος πίνακας. Συνεπώς,

$$\frac{d}{dt}[PP^{-1}] = 0$$

ή ισοδύναμα

$$\dot{P}P^{-1} + P\frac{d}{dt}[P^{-1}] = 0 \tag{4.2.8}$$

Λύνοντας την (4.2.8) ως προς $\dot{P}$ έχουμε:

$$\dot{P} = -P\left(\frac{d}{dt}P^{-1}\right)P \tag{4.2.9}$$

Από την (4.2.7) βρίσκουμε ότι:

$$P^{-1}(t) = e^{-\beta t}Q_0 + \int_0^t e^{-\beta(t-\tau)}\phi(\tau)\phi^T(\tau)d\tau \tag{4.2.10}$$

Γνωρίζουμε ότι αν έχουμε την διαφορική εξίσωση $\dot{z} = -\beta z + v$, τότε η λύση της είναι:

$$z(t) = z(0)e^{-\beta t} + \int_0^t e^{-\beta(t-\tau)}v(\tau)d\tau \tag{4.2.11}$$

Παρατηρούμε λοιπόν ότι η (4.2.10) είναι στην μορφή (4.2.11), άρα αποτελεί την λύση της διαφορικής εξίσωσης:

$$\frac{d}{dt}P^{-1} = -\beta P^{-1} + \phi\phi^T, \qquad P^{-1}(0) = Q_0 \tag{4.2.12}$$

Αντικαθιστώντας την (4.2.12) στην (4.2.9) προκύπτει:

$$\begin{aligned} \dot{P} &= -P[-\beta P^{-1} + \phi\phi^T]P \\ &= \beta P - P\phi\phi^T P, \quad P(0) = Q_0^{-1} \end{aligned} \tag{4.2.13}$$

Ομοίως παρατηρούμε ότι η (4.2.6) γράφεται:

$$\hat{\theta}(t) = P(t)\Omega(t) \tag{4.2.14}$$
$$\dot{\Omega} = -\beta\Omega + y\phi, \quad \Omega(0) = Q_0\hat{\theta}(0) \tag{4.2.15}$$

Παραγωγίζοντας την (4.2.14) ως προς τον χρόνο βρίσκουμε:

$$\begin{aligned}\dot{\hat{\theta}} &= \dot{P}\Omega + P\dot{\Omega} \\ &= [\beta P - P\phi\phi^T P]\Omega + P[-\beta\Omega + y\phi] \\ &= -P\phi\phi^T P\Omega + Py\phi \\ &= P\phi[-\phi^T P\Omega + y] \end{aligned} \tag{4.2.16}$$

Όμως, $P(t)\Omega(t) = \hat{\theta}(t)$ και η (4.2.16) παίρνει την μορφή:

$$\dot{\hat{\theta}} = P\phi[-\phi^T\hat{\theta} + y] \tag{4.2.17}$$

Αντικαθιστώντας την (4.2.3) στην (4.2.17) καταλήγουμε στην εξίσωση:

$$\dot{\hat{\theta}} = P(t)\tilde{y}(t)\phi(t) \tag{4.2.18}$$

Οι (4.2.13), (4.2.18) αποτελούν την αναδρομική έκφραση της μεθόδου των ελαχίστων τετραγώνων με απώλεια μνήμης. Η παράμετρος β ονομάζεται ρυθμός απώλειας μνήμης.

Μηδενικός ρυθμός απώλειας μνήμης

Ας θεωρήσουμε την περίπτωση όπου $\beta = 0$. Τότε η αναδρομική έκφραση της μεθόδου των ελαχίστων τετραγώνων παίρνει την μορφή:

$$\dot{\hat{\theta}} = P\tilde{y}\phi \tag{4.2.19}$$
$$\dot{P} = -P\phi\phi^T P, \quad P(0) = Q_0^{-1} \tag{4.2.20}$$

Όπως προέκυψε από την ανάλυση που προηγήθηκε,

$$\frac{d}{dt}P^{-1} = \phi\phi^T \geq 0 \tag{4.2.21}$$

Συνεπώς, ο P^{-1} μπορεί να αυξάνει δίχως όριο, το οποίο ερμηνεύεται ότι ο P μπορεί να παίρνει πολύ μικρές τιμές και κατά συνέπεια να επιβραδύνει την μεταβολή του $\hat{\theta}$ σε κάποιες κατευθύνσεις. Πέρα απ' αυτό το μειονέκτημα, το οποίο θα το αντιμετωπίσουμε παρακάτω, η αναδρομική έκφραση της μεθόδου των ελαχίστων τετραγώνων έχει και σημαντικά πλεονεκτήματα.

Από την (4.2.20) παρατηρούμε ότι $\dot{P} \leq 0$. Επίσης, όπως φαίνεται από την (4.2.7), $P(t) \geq 0, \ \forall t \geq 0$. Επομένως, η $P(t)$ ως φθίνουσα και φραγμένη από κάτω από το μηδέν θα έχει όριο

$$\lim_{t\to\infty} P(t) = \bar{P}$$

όπου $\bar{P} \geq 0$ κάποιος σταθερός πίνακας. Θεωρείστε τώρα:

$$\frac{d}{dt}\left(P^{-1}\tilde{\theta}\right) = \left[\frac{d}{dt}\left(P^{-1}\right)\right]\tilde{\theta} + P^{-1}\dot{\tilde{\theta}} \tag{4.2.22}$$

Αντικαθιστώντας τις (4.2.21), (4.2.19) στην (4.2.22) προκύπτει:

$$\frac{d}{dt}\left(P^{-1}\tilde{\theta}\right) = \phi\phi^T\tilde{\theta} + P^{-1}P\tilde{y}\phi \tag{4.2.23}$$

Από τις (4.2.1) και (4.2.3) έχουμε ότι $\tilde{y} = -\tilde{\theta}^T\phi$. Επομένως,

$$\frac{d}{dt}\left(P^{-1}\tilde{\theta}\right) = -\phi\tilde{y} + \tilde{y}\phi = 0 \tag{4.2.24}$$

Συνεπώς,

$$P^{-1}(t)\tilde{\theta}(t) = P^{-1}(0)\tilde{\theta}(0)$$

ή

$$\tilde{\theta}(t) = P(t)P^{-1}(0)\tilde{\theta}(0)$$

Άρα

$$\lim_{t\to\infty}\tilde{\theta}(t) = \left[\lim_{t\to\infty}P(t)\right]P^{-1}(0)\tilde{\theta}(0) = \bar{P}P^{-1}(0)\tilde{\theta}(0)$$

ή

$$\lim_{t\to\infty}\hat{\theta}(t) = \theta^\star + \bar{P}P^{-1}(0)\tilde{\theta}(0) = \bar{\theta}$$

όπου $\bar{\theta}$ μια σταθερά. Επιπλέον, επειδή $P(t) \leq P(0)$ και $\tilde{\theta}(t) = P(t)P^{-1}(0)\tilde{\theta}(0)$, προκύπτει ότι $\hat{\theta}(t) \in L_\infty$ το οποίο μαζί με την υπόθεση ότι $\phi \in L_\infty$ μας δίνει $\tilde{y} = -\tilde{\theta}^T\phi \in L_\infty$.

Ας πάρουμε τώρα την συνάρτηση Lyapunov

$$V = \frac{\tilde{\theta}^T P^{-1}(t)\tilde{\theta}}{2} \tag{4.2.25}$$

Παραγωγίζοντας την V ως προς τον χρόνο βρίσκουμε:

$$\begin{aligned}
\dot{V} &= \frac{1}{2}\dot{\tilde{\theta}}^T P^{-1}\tilde{\theta} + \frac{1}{2}\tilde{\theta}^T P^{-1}\dot{\tilde{\theta}} + \frac{\tilde{\theta}^T\frac{d}{dt}(P^{-1})\tilde{\theta}}{2} \\
&= \tilde{y}\tilde{\theta}^T\phi + \tilde{\theta}^T\frac{\phi\phi^T}{2}\tilde{\theta} \\
&= -\tilde{y}^2 + \frac{\tilde{y}^2}{2} \\
&= -\frac{\tilde{y}^2}{2} \leq 0
\end{aligned} \tag{4.2.26}$$

Από την (4.2.26) καταλήγουμε στο συμπέρασμα ότι $\tilde{y} \in L_2$, ενώ από την (4.2.19)

$$|\dot{\hat{\theta}}| \leq \|P\||\tilde{y}||\phi| \tag{4.2.27}$$

Επειδή $\|P\|, |\phi|, |\tilde{y}| \in L_\infty$ και $|\tilde{y}| \in L_2$ προκύπτει ότι $|\dot{\hat{\theta}}| \in L_2 \bigcap L_\infty$. Η παραπάνω ανάλυση συνοψίζεται στο συμπέρασμα:

Συμπέρασμα 4.2.1 Θεωρείστε το σύστημα (4.2.1) και το σύστημα αναγνώρισης (4.2.3). Η αναδρομική έκφραση της μεθόδου των ελαχίστων τετραγώνων με μηδενικό συντελεστή απώλειας μνήμης που περιγράφεται από τις (4.2.19), (4.2.20) εγγυάται ότι:

- $\tilde{y},\ \hat{\theta},\ \dot{\hat{\theta}},\ P \in L_\infty$,
- $\tilde{y},\ \dot{\hat{\theta}} \in L_2$,
- $\lim_{t\to\infty} \hat{\theta}(t) = \bar{\theta}$ όπου $\bar{\theta}$ ένα σταθερό διάνυσμα.

Επιπλέον, αν $\phi \in L_\infty$ και το ϕ ικανοποιεί μια ΣΕΔ, τότε το $\hat{\theta}(t)$ θα συγκλίνει στο $\theta^\star$ καθώς $t \to \infty$.

Τροποποιήσεις της αναδρομικής έκφρασης της μεθόδου των ελαχίστων τετραγώνων

Το πρόβλημα του να γίνει ο $P(t)$ ιδιόμορφος (singular), μπορεί να αποφευχθεί τροποποιώντας κατάλληλα τις διαφορικές εξισώσεις (4.2.19), (4.2.20). Μια τέτοια τροποποίηση στηρίζεται στην επανεκκίνηση (resetting), της (4.2.20) κάθε φορά που η ελάχιστη ιδιοτιμή του $P(t)$ κατέβει ένα κατώφλι. Μ' άλλα λόγια:

$$\begin{aligned} \dot{\hat{\theta}} &= P\tilde{y}\phi \\ \dot{P} &= -P\phi\phi^T P, \quad P(t_r^+) = \rho_0 I \end{aligned} \tag{4.2.28}$$

όπου με t_r συμβολίζουμε την χρονική στιγμή κατά την οποία $\lambda_{min}(P) \le \rho_1$ και $\rho_0 > \rho_1 > 0$ είναι κάποιες σταθερές. Εξαιτίας της (4.2.28), $P(t) \ge \rho_1 I, \quad \forall t \ge 0$. Συνεπώς, εξασφαλίζουμε ότι ο $P(t)$ θα είναι θετικά ορισμένος $\forall t \ge 0$. Για να ακριβολογούμε, η παραπάνω τροποποίηση δεν αποτελεί πλέον μέθοδο ελαχίστων τετραγώνων με την έννοια της ελαχιστοποίησης του $\nabla K(\hat{\theta})$. Συμπεριφέρεται όμως σαν τέτοια στα χρονικά διαστήματα μεταξύ των επανεκκινήσεων.

Αν θεωρήσουμε μη-μηδενικό συντελεστή απώλειας μνήμης $\beta > 0$, το πρόβλημα του να γίνει ο $P(t)$ πολύ μικρός όπως περιγράφηκε σε προηγούμενες ενότητες, δεν υφίσταται πλέον. Στην περίπτωση αυτή ισχύουν οι εξισώσεις (4.2.13), (4.2.18). Παρατηρήστε τώρα ότι επειδή $\beta P(t) > 0$ και ο παράγοντας $P\phi\phi^T P$ είναι θετικά ημιορισμένος είναι δυνατόν $\dot{P} > 0$ για αρκούντως μεγάλο χρονικό διάστημα, με αποτέλεσμα ο $P(t)$ να αυξάνει δίχως όριο. Ένας τρόπος να ξεπεραστεί το παραπάνω πρόβλημα είναι να χρησιμοποιήσουμε την τροποποίηση:

$$\begin{aligned} \dot{\hat{\theta}} &= P\tilde{y}\phi \\ \dot{P} &= \begin{cases} \beta P - P\phi\phi^T P, & \text{αν } \|P(t)\| \le \bar{R} \\ 0, & \text{διαφορετικά} \end{cases} \end{aligned} \tag{4.2.29}$$

όπου $\|P(0)\| \le \bar{R}$ με την σταθερά $\bar{R}$ να συμβολίζει το επιθυμητό άνω φράγμα της $\|P(t)\|$. Προφανώς, η τροποποίηση (4.2.29) εγγυάται ότι $P(t) \in L_\infty$.

4.3 Αναδρομικοί Αλγόριθμοι Προβολής

Στις προηγούμενες ενότητες μελετήσαμε αναδρομικούς αλγόριθμους εκτίμησης των παραμέτρων του μοντέλου όταν ο χώρος αναζήτησης ήταν ο $\Re^n$. Σε περιπτώσεις όμως που οι άγνωστες παράμετροι έχουν φυσική ερμηνεία, είναι πολύ πιθανό ο χώρος αναζήτησης να μην είναι άπειρος αλλά περιορισμένος εντός ορίων ή γενικότερα εντός ενός καλά ορισμένου υποσύνολου του $\Re^n$. Γνωρίζοντας την περιοχή στην οποία ανήκει μια άγνωστη παράμετρος, θα μπορούσαμε να σχεδιάσουμε κατάλληλους αναδρομικούς αλγόριθμους που να ψάχνουν αποκλειστικά εντός αυτής. Διαισθητικά αναμένουμε βελτίωση τόσο στην ταχύτητα σύγκλισης, όσο και στο μέγεθος των μεταβατικών φαινομένων.

4.3.1 Αλγόριθμος κλίσης με προβολή

Έστω ότι μας ενδιαφέρει η ελαχιστοποίηση μιας συνάρτησης κόστους $K(\hat{\theta})$ με το $\hat{\theta}$ να παίρνει τιμές μέσα από ένα καλά ορισμένο κυρτό σύνολο:

$$\Theta = \left\{ \hat{\theta} \in \Re^n : g(\hat{\theta}) \leq 0 \right\} \tag{4.3.1}$$

όπου η $g(\hat{\theta})$ είναι στην γενικότερη περίπτωση διανυσματική με διάσταση όση και το πλήθος των περιορισμών. Αντί λοιπόν να ψάχνουμε το $\hat{\theta}$ που ελαχιστοποιεί την $K(\hat{\theta})$ σ' όλοκληρο τον $\Re^n$, το αναζητάμε σ' ένα κατάλληλα ορισμένο υποσύνολό του $\Theta \subset \Re^n$.

Προκειμένου να παρουσιάσουμε την μέθοδο της προβολής, θα ξεκινήσουμε με την απλούστερη περίπτωση όπου έχουμε να ικανοποιήσουμε ένα μόνο ανισωτικό περιορισμό. Θέλουμε λοιπόν να υπολογίσουμε:

$$\arg\min_{\hat{\theta} \in \Theta} K(\hat{\theta}) \tag{4.3.2}$$

όπου το Θ είναι όπως ορίστηκε στην (4.3.1).

Η λογική του αλγορίθμου είναι η εξής: Εκκινούμε από κάποιο σημείο $\hat{\theta}(0) = \hat{\theta}_0$ εσωτερικό του Θ και ακολουθούμε την λύση που παρέχει ο αναδρομικός αλγόριθμος που σχεδιάστηκε σαν να μην είχαμε περιορισμούς. Στην περίπτωση του αλγορίθμου κλίσης $\dot{\hat{\theta}} = -\Gamma \nabla K(\hat{\theta})$. Μόλις φθάσουμε στο σύνορο του Θ, όταν δηλαδή $g(\hat{\theta}) = 0$, ελέγχουμε αν το $\hat{\theta}$ έχει την τάση να κινηθεί εκτός του Θ. Αν όχι, εξακολουθούμε να χρησιμοποιούμε τον ίδιο αλγόριθμο. Στην αντίθετη περίπτωση όμως, του προσθέτουμε ένα παράγοντα που το αναγκάζει να κινηθεί προς το εσωτερικό του Θ ή πάνω στο σύνορο αυτού.

Ένας αλγόριθμος που πετυχαίνει το παραπάνω αποτέλεσμα είναι:

$$\dot{\hat{\theta}} = \Pi\left(-\Gamma \nabla K\right) = \begin{cases} -\Gamma \nabla K(\hat{\theta}), & \text{αν } \hat{\theta} \in \Theta_{in} \text{ ή αν} \\ & \hat{\theta} \in \Theta_b \text{ και } -(\Gamma \nabla K)^T \nabla g \leq 0 \\ -\Gamma \nabla K(\hat{\theta}) + \Gamma \frac{\nabla g \nabla g^T}{\nabla g^T \Gamma \nabla g} \Gamma \nabla K(\hat{\theta}), & \text{διαφορετικά} \end{cases} \tag{4.3.3}$$

όπου Θ_{in} είναι το εσωτερικό του Θ και Θ_b το σύνορο του Θ. Στην (4.3.3), $\hat{\theta}(0) \in \Theta$. Στο Σχ. 4.3, δίνεται γεωμετρικά η λειτουργία του αλγορίθμου κλίσης με προβολή.

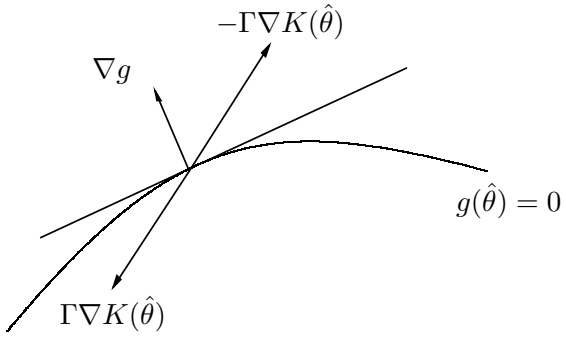

Σχήμα 4.3: Γεωμετρική αναπαράσταση της λειτουργίας του αλγορίθμου κλίσης με προβολή.

Όπως φαίνεται και από το Σχ. 4.3, όταν βρισκόμαστε πάνω στο σύνορο του Θ και το εσωτερικό γινόμενο $\dot{\hat{\theta}}^T\nabla g \leq 0$, τότε η τάση είναι το $\hat{\theta}$ να κινηθεί προς το εσωτερικό του Θ ή στην χειρότερη περίπτωση πάνω στο σύνορο Θ_b. Εξετάζοντας το πρόσημο του $\dot{\hat{\theta}}^T\nabla g$, όταν $\hat{\theta} \in \Theta_b$ και $\hat{\theta}$ δίνεται από την (4.3.3), παρατηρούμε ότι όταν $\hat{\theta} \in \Theta_b$ και $-(\Gamma\nabla K)^T\nabla g \leq 0$ τότε προφανώς $\dot{\hat{\theta}}^T\nabla g \leq 0$. Στην περίπτωση που $\hat{\theta} \in \Theta_b$ και $-(\Gamma\nabla K)^T\nabla g > 0$ έχουμε:

$$\begin{aligned}
\dot{\hat{\theta}}^T\nabla g &= -(\Gamma\nabla K)^T\nabla g + (\Gamma\nabla K)^T\frac{\nabla g\nabla g^T}{\nabla g^T\Gamma\nabla g}\Gamma^T\nabla g \\
&= -(\Gamma\nabla K)^T\nabla g + (\Gamma\nabla K)^T\nabla g\frac{\nabla g^T\Gamma\nabla g}{\nabla g^T\Gamma\nabla g} \\
&= 0
\end{aligned}$$

Συνεπώς ο (4.3.3) εγγυάται ότι το $\hat{\theta} \in \Theta, \quad \forall t \geq 0$, με την προϋπόθεση ότι $\hat{\theta}(0) \in \Theta$. Γενικά αποδεικνύεται το παρακάτω Θεώρημα που περιγράφει τις ιδιότητες του αλγορίθμου κλίσης με προβολή.

Θεώρημα 4.3.1 *Ο αναδρομικός αλγόριθμος κλίσης με ενσωματωμένη προβολή (4.3.3), διατηρεί της ιδιότητές του απουσία προβολής και επιπλέον εξασφαλίζει ότι $\hat{\theta} \in \Theta, \quad \forall t \geq 0$, με την προϋπόθεση ότι τόσο η αρχική τιμή $\hat{\theta}(0)$ όσο και η άγνωστη παράμετρος $\theta^\star$ ανήκουν στο κυρτό σύνολο Θ.*

Τα αποτελέσματα του Θεωρήματος 4.3.1 μεταφέρονται αυτούσια και στην περίπτωση όπου αντί του αναδρομικού αλγορίθμου κλίσης χρησιμοποιηθεί η μέθοδος σχεδίασης αναδρομικών αλγορίθμων εκτίμησης παραμέτρων κατά Lyapunov.

4.3.2 Αναδρομικός αλγόριθμος ελαχίστων τετραγώνων με προβολή

Όπως και στην περίπτωση του αναδρομικού αλγορίθμου κλίσης, η προβολή μπορεί να ενσωματωθεί και στον αναδρομικό αλγόριθμο των ελαχίστων τετραγώνων προκειμένου να εξασφαλίσουμε ότι $\hat{\theta} \in \Theta, \quad \forall t \geq 0$, με την προϋπόθεση ότι $\hat{\theta}(0), \theta^\star \in \Theta$. Επίσης, η προσθήκη της προβολής δεν αλλοιώνει τις ιδιότητες ευστάθειας και σύγκλισης του αλγορίθμου χωρίς την προβολή.

Ο αναδρομικός αλγόριθμος ελαχίστων τετραγώνων με προβολή δίνεται από:

$$\dot{\hat{\theta}} = \Pi\left(P\tilde{y}\phi\right) = \begin{cases} P\tilde{y}\phi, & \text{αν } \hat{\theta} \in \Theta_{in} \text{ ή αν} \\ & \hat{\theta} \in \Theta_b \text{ και } (P\tilde{y}\phi)^T \nabla g \leq 0 \\ P\tilde{y}\phi - P\frac{\nabla g \nabla g^T}{\nabla g^T P \nabla g} P\tilde{y}\phi, & \text{διαφορετικά} \end{cases} \tag{4.3.4}$$

και $\hat{\theta}(0) \in \Theta$ και

$$\dot{P} = \begin{cases} \beta P - P\phi\phi^T P, & \text{αν } \hat{\theta} \in \Theta_{in} \text{ ή αν} \\ & \hat{\theta} \in \Theta_b \text{ και } (P\tilde{y}\phi)^T \nabla g \leq 0 \\ 0, & \text{διαφορετικά} \end{cases} \tag{4.3.5}$$

όπου $P(0) = P_0 = P_0^T > 0$.

Παρατηρήστε ότι η (4.3.5) έχει τροποποιηθεί κατά τρόπο ώστε όταν εφαρμόζεται η προβολή στο $\hat{\theta}$ ο P να είναι ένας σταθερός πίνακας. Συνεπώς, η (4.3.4) συμπεριφέρεται στο σημείο αυτό σαν ένας αλγόριθμος κλίσης με προβολή.

Κεφάλαιο 5

ΕΠΙΛΟΓΗ ΔΟΜΗΣ & ΑΞΙΟΛΟΓΗΣΗ ΜΟΝΤΕΛΟΥ

Το πρώτο βήμα στην μοντελοποίηση ενός συστήματος - διαδικασίας, είναι η επιλογή μιας μαθηματικής έκφρασης που να το αντιπροσωπεύει, μέσα από ένα πλήθος προσφερόμενων εκφράσεων. Για παράδειγμα, θέλουμε να χρησιμοποιήσουμε γραμμικό ή μη-γραμμικό μοντέλο; Αν γραμμικό, θα επιλέξουμε εξισώσεις κατάστασης ή συνάρτηση μεταφοράς; Αν μη-γραμμικό, θέλουμε να είναι γραμμικό, μη-γραμμικό ή μεικτό ως προς τις παραμέτρους;

Με δεδομένη την επιλογή του μοντέλου, επόμενο βήμα αποτελεί η σύνθεση της δομής του. Για να κατανοήσουμε καλύτερα το πρόβλημα, θεωρείστε ότι έχουμε επιλέξει ένα γραμμικό σύστημα της μορφής:

$$y = \theta^{\star T}\phi$$

Το πρόβλημα της σύνθεσης για το μοντέλο αυτό επιμερίζεται ως εξής:

- Υπολογισμός της διάστασης του διανύσματος οπισθοδρόμησης ϕ,
- προσδιορισμός των οπισθοδρομητών (στοιχεία του ϕ),
- προσδιορισμός των άγνωστων παραμέτρων $\theta^\star$ του μοντέλου.

Το τρίτο και τελευταίο αλλά πολύ σημαντικό βήμα στην μοντελοποίηση ενός συστήματος, αποτελεί η αξιολόγηση του μοντέλου που προέκυψε από τα δύο προηγούμενα βήματα. Μ' άλλα λόγια πόσο 'καλό' είναι το μοντέλο σε σχέση με την εφαρμογή που θέλουμε να το ενσωματώσουμε; Όλα τα μοντέλα δεν αποδίδουν εξίσου 'καλά' για όλες τις πιθανές εφαρμογές. Για παράδειγμα, αν η εφαρμογή είναι ο αυτόματος έλεγχος ενός συστήματος, ένα 'καλό' γραμμικό μοντέλο είναι προτιμητέο από ένα εξίσου 'καλό' (ίσως και καλύτερο) μη-γραμμικό, λόγω της ύπαρξης πληθώρας εργαλείων ανάλυσης - σύνθεσης γραμμικών ελεγκτών. Αν όμως η εφαρμογή είναι η προσομοίωση ή η πρόβλεψη της συμπεριφοράς ενός συστήματος, τότε ένα 'καλό' μη-γραμμικό μοντέλο το οποίο θα περιέγραφε με ικανοποιητική ακρίβεια τα μη-γραμμικά φαινόμενα που επηρεάζουν την λειτουργία του, σίγουρα θα υπερτερούσε έναντι ενός γραμμικού.

Όπως φάνηκε από την συζήτηση που προηγήθηκε, η επίλυση του προβλήματος της μοντελοποίησης συστημάτων ακολουθεί τρία βήματα. Στην πράξη όμως ένας τέτοιος αυστηρός διαχωρισμός δεν είναι πάντα εφικτός. Ειδικά τα βήματα 2 και 3 είναι ισχυρά συνδεδεμένα σε βαθμό που να εκτελούνται πρακτικά παράλληλα.

Στα κεφάλαια που προηγήθηκαν, είδαμε κάποιες γενικές δομές μοντέλων, τόσο γραμμικές όσο και μη-γραμμικές, μιλήσαμε για τις παραμετροποιήσεις τους και μελετήσαμε αλγόριθμους (αναδρομικούς και μη) προσδιορισμού των παραμέτρων τους.

Στο κεφάλαιο αυτό δεν θα ασχοληθούμε με μια συγκεκριμένη δομή ή με κάποιον αλγόριθμο προσδιορισμού παραμέτρων. Αντιθέτως, η ύλη που θα παρουσιαστεί έχει γενικό χαρακτήρα. Η έννοια της ποιότητας ενός μοντέλου που είναι συνυφασμένη με την αξιολόγησή του, ισχύει για κάθε τύπο μοντέλου. Την ίδια γενικότητα θα προσπαθήσουμε να ακολουθήσουμε και στην συζήτηση περί σύνθεσης της δομής του μοντέλου.

5.1 Σφάλματα Μοντελοποίησης

Ας θεωρήσουμε ένα σύστημα από το οποίο μπορούμε να μετρήσουμε μόνο τις εισόδους και τις εξόδους του. Υποθέτοντας για μια στιγμή ότι η δομή του συστήματος μας είναι πλήρως γνωστή, γνωρίζουμε δηλαδή με απόλυτη ακρίβεια την μαθηματική έκφραση των μη-γραμμικοτήτων του, αλλά αγνοούμε την τιμή κάποιων παραμέτρων $\theta^\star$, τότε μπορούμε να γράψουμε ότι:

$$y = \theta^{\star T}\phi \tag{5.1.1}$$

Για να γράψουμε την (5.1.1) θεωρήσαμε ότι το σύστημα παραμετροποιείται γραμμικά, ενώ το διάνυσμα οπισθοδρόμησης μπορεί να περιέχει και μη-γραμμικά στοιχεία. Την γραμμική παραμετροποίηση την εισάγουμε εδώ αποκλειστικά και μόνο για λόγους απλότητας στην παρουσίαση και εύκολης κατανόησης των εννοιών. Αν θέλουμε να περιγράψουμε λεκτικά την (5.1.1), θα λέγαμε ότι αυτή αποτελεί την πλήρη μαθηματική αναπαράσταση του συστήματός μας. Για προεπιλεγμένο διάνυσμα οπισθοδρομητών ϕ, το μόνο που απομένει για την επίλυση του προβλήματος της μοντελοποίησης είναι ο προσδιορισμός του άγνωστου διανύσματος $\theta^\star$.

Σφάλμα πόλωσης

Για να γράψουμε την (5.1.1) υποθέσαμε την πλήρη γνώση της δομής του συστήματος. Κάτι τέτοιο στην πράξη είναι ανεφάρμοστο. Όσο καλά και αν θεωρούμε ότι κατέχουμε το σύστημά μας, πάντα θα υπάρχουν άγνωστες (μη μοντελοποιημένες) μη-γραμμικότητες, εξαιτίας της πολυπλοκότητας που διέπουν τα περισσότερα (αν όχι όλα) τα πραγματικά συστήματα - διαδικασίες. Στην περίπτωση αυτή, ακόμα και αν γνωρίζαμε το $\theta^\star$, η έξοδος του πραγματικού συστήματος δεν θα περιγράφονταν από την (5.1.1) αλλά από την:

$$y = \theta^{\star T}\phi + \omega \tag{5.1.2}$$

Στην (5.1.2), ο όρος ω μπορεί να θεωρηθεί ως το σφάλμα προσέγγισης της εξόδου y του πραγματικού συστήματος, από το $\theta^{\star T}\phi$. Το ω δεν εξαρτάται ποιοτικά από το $\theta^\star$, αλλά από το ϕ. Αυτό είναι

λογικό διότι το ϕ απαρτίζεται από τις συναρτήσεις βάσης. Το $\theta^{\star T}\phi$ εκφράζει απλά τον γραμμικό συνδυασμό τους. Το παράδειγμα που ακολουθεί κάνει πιο κατανοητό το παραπάνω επιχείρημα.

Παράδειγμα 5.1.1 Θεωρείστε ότι το πραγματικό σύστημα είναι της μορφής:

$$y = \sum_{j=0}^{5} \theta_j x^j, \qquad \forall x \in [a, b] \tag{5.1.3}$$

Αν χρησιμοποιήσουμε ως μοντέλο το:

$$y = \sum_{j=0}^{2} \hat{\theta}_j x^j, \qquad \forall x \in [a, b] \tag{5.1.4}$$

τότε δεν είναι δυνατόν να πετύχουμε $y = \hat{y}$ για οποιαδήποτε $\hat{\theta}_j, \;\; j = 0, 1, 2$ και $x \in [a, b]$. Αν όμως χρησιμοποιούσαμε το μοντέλο:

$$y = \sum_{j=0}^{5} \hat{\theta}_j x^j, \qquad \forall x \in [a, b] \tag{5.1.5}$$

τότε $y = \hat{y}, \;\; \forall x \in [a, b]$ αν $\hat{\theta}_j = \theta_j^\star, \;\; j = 0, 1, 2, 3, 4, 5$.

Το σφάλμα προσέγγισης ω καλείται στην διεθνή βιβλιογραφία *σφάλμα πόλωσης* (bias error).

Σφάλμα διασποράς

Στην προηγούμενη παράγραφο αναφερθήκαμε στο σφάλμα πόλωσης. Μια άλλη πηγή σφαλμάτων μοντελοποίησης εισάγεται από την αδυναμία μας να προσδιορίσουμε με ακρίβεια την τιμή των άγνωστων παραμέτρων $\theta^\star$.

Έστω λοιπόν $\omega = 0$. Το πραγματικό σύστημα θα περιγράφεται από την (5.1.1). Θεωρείστε το σύστημα αναγνώρισης με εκτιμώμενη τιμή για το $\theta^\star$ την $\hat{\theta}$

$$\hat{y} = \hat{\theta}^T \phi \tag{5.1.6}$$

Από τις (5.1.1) και τις (5.1.6) προκύπτει το σφάλμα αναγνώρισης:

$$\tilde{y} = y - \hat{y} = -\tilde{\theta}^T \phi \tag{5.1.7}$$

όπου το παραμετρικό σφάλμα $\tilde{\theta} = \hat{\theta} - \theta^\star$.

Όπως είδαμε στο Κεφάλαιο 3 αλλά κυρίως στο Κεφάλαιο 4, για να συγκλίνει το $\hat{\theta}$ στο $\theta^\star$, ακόμα και αν έχουμε άπειρα δεδομένα στην διάθεσή μας, θα πρέπει το διάνυσμα των οπισθοδρομητών ϕ να ικανοποιεί μια ΣΕΔ. Στην γενική περίπτωση που το ϕ περιέχει μη-γραμμικά στοιχεία, η ικανοποίηση της ΣΕΔ δεν μπορεί να εξασφαλιστεί εκ των προτέρων. Συνεπώς, στην πράξη δεν μπορούμε να εγγυηθούμε όχι μόνο την σύγκλιση του $\hat{\theta}$ στο $\theta^\star$, αλλά ακόμα και την ιδιότητα του $\hat{\theta}$ να συγκλίνει σε κάποια σταθερή τιμή.

Με δεδομένο λοιπόν ότι στην γενική περίπτωση $\tilde{\theta} \neq 0$ η (5.1.7) μας δίνει σφάλμα μοντελοποίησης $\tilde{y} \neq 0$. Το σφάλμα μοντελοποίησης που οφείλεται στην ύπαρξη παραμετρικού σφάλματος ονομάζεται στην διεθνή βιβλιογραφία *σφάλμα διασποράς* (variance error).

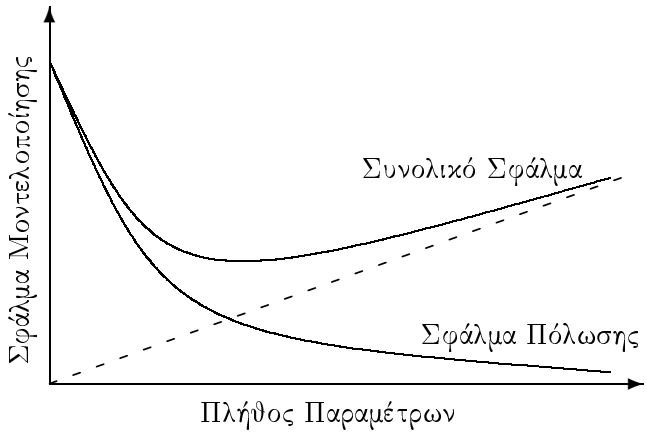

Σχήμα 5.1: Τυπική συμπεριφορά του σφάλματος μοντελοποίησης με το πλήθος των παραμέτρων. Με διακεκομμένες γραμμές απεικονίζεται το σφάλμα διασποράς.

Ελαχιστοποίηση του σφάλματος μοντελοποίησης

Όπως είδαμε, το σφάλμα μοντελοποίησης αναλύεται σε δύο όρους. Το σφάλμα πόλωσης και το σφάλμα διασποράς. Πράγματι, χρησιμοποιώντας τις (5.1.2) και (5.1.6) προκύπτει:

$$\tilde{y} = y - \hat{y} = \theta^{\star T}\phi + \omega - \hat{\theta}^T\phi = -\tilde{\theta}^T\phi + \omega \tag{5.1.8}$$

Μια εκτίμηση του μεγέθους του σφάλματος μοντελοποίησης αποτελεί η έκφραση:

$$|\tilde{y}| = |-\tilde{\theta}^T\phi + \omega| \leq |\tilde{\theta}^T\phi| + |\omega| \leq |\tilde{\theta}||\phi| + |\omega| \tag{5.1.9}$$

Εξ ορισμού, το σφάλμα πόλωσης ω μειώνεται αν αυξήσουμε το πλήθος των συναρτήσεων βάσης, ή κατ' επέκταση αν αυξήσουμε την διάσταση του διανύσματος ϕ. Αυξάνοντας όμως την διάσταση του ϕ, αυξάνουμε ταυτόχρονα και την διάσταση του $\theta^\star$, άρα και του παραμετρικού σφάλματος $\tilde{\theta}$. Κατά συνέπεια αυξάνει η νόρμα $|\tilde{\theta}|$ που εμφανίζεται στην (5.1.9). Στην προσπάθεια μας λοιπόν να μειώσουμε το σφάλμα πόλωσης, αυξάνουμε το σφάλμα διασποράς. Αν θέλουμε να κρατήσουμε το σφάλμα διασποράς χαμηλό, θα πρέπει να θεωρήσουμε χαμηλή την διάσταση του ϕ. Επειδή το πλήθος των συναρτήσεων βάσης που χρησιμοποιούνται στο ϕ είναι άμεσα συνδεδεμένο με την πολυπλοκότητα του μοντέλου, θα λέμε ότι ένα πολύπλοκο μοντέλο εμφανίζει μικρό σφάλμα πόλωσης, ενώ ένα λιγότερο πολύπλοκο εμφανίζει μικρό σφάλμα διασποράς. Μια τυπική συμπεριφορά του σφάλματος μοντελοποίησης με το πλήθος των παραμέτρων, εικονίζεται στο Σχ. 5.1.

Όπως φαίνεται και από το Σχ. 5.1, για μικρό πλήθος παραμέτρων, το σφάλμα πόλωσης κυριαρχεί, που σημαίνει ότι μικρή αύξηση στο πλήθος των παραμέτρων θα συνοδεύεται από σημαντική μείωση του σφάλματος μοντελοποίησης. Το σφάλμα πόλωσης είναι φθίνουσα συνάρτηση του πλήθους των παραμέτρων, που σημαίνει ότι μπορούμε να αυξάνουμε τις παραμέτρους και να οδηγούμαστε σε ολοένα και μικρότερο σφάλμα πόλωσης. Δυστυχώς, ακριβώς το αντίθετο συμβαίνει με το σφάλμα διασποράς. Από ένα αριθμό παραμέτρων και πάνω, το σφάλμα διασποράς κυριαρχεί και η

συμπεριφορά του είναι εκείνη που καθορίζει το σφάλμα μοντελοποίησης. Αυτό που παρατηρούμε στην πράξη και εικονίζεται ξεκάθαρα στο Σχ. 5.1, είναι ότι αύξηση του αριθμού των παραμέτρων του μοντέλου (και κατ' επέκταση του αριθμού των συναρτήσεων βάσης) πάνω απ' ένα κατώφλι, θα οδηγήσει σε αύξηση του σφάλματος μοντελοποίησης.

Κεντρικό θέμα στο πρόβλημα της μοντελοποίησης συστημάτων, αποτελεί η εύρεση του βέλτιστου αριθμού παραμέτρων - συναρτήσεων βάσης, μια και συνδέεται άμεσα με την επιλογή της δομής και κατ' επέκταση με την ποιότητα του μοντέλου.

Είναι σημαντικό να κατανοήσουμε, ότι η εύρεση του αριθμού των παραμέτρων που ελαχιστοποιεί το σφάλμα μοντελοποίησης, δεν αποτελεί και την βέλτιστη λύση στο πρόβλημα της μοντελοποίησης ενός συστήματος. Εκφράζει όμως την βέλτιστη υλοποίηση για μια προεπιλεγμένη δομή μοντέλου. Όπως είδαμε και στο Κεφάλαιο 2, υπάρχει πληθώρα δομών, γραμμικών και μη, που δυνητικά μπορούν να αποτελέσουν εξίσου 'καλά' μοντέλα του συστήματός μας. Συνεπώς, μια άλλη δομή θα μπορούσε να περιγράψει το ίδιο σύστημα με μικρότερο αριθμό (διαφορετικών εν γένη) συναρτήσεων βάσης, το οποίο ερμηνεύεται σε μικρότερο ή ίδιο σφάλμα πόλωσης, με μικρότερο σφάλμα διασποράς. Μ' άλλα λόγια, το σφάλμα μοντελοποίησης είναι και συνάρτηση της δομής του μοντέλου που επιλέχθηκε για να περιγράψει το σύστημά μας. Για κάθε δομή υπάρχει η βέλτιστη υλοποίηση που αντιστοιχεί στην ελαχιστοποίηση του σφάλματος μοντελοποίησης.

Υπερεκμάθηση - υποεκμάθηση

Για την καλύτερη κατανόηση των εννοιών που θα ακολουθήσουν ας ορίσουμε δύο διαφορετικούς τύπους δεδομένων:

- **Δεδομένα Εκμάθησης** (Training Data). Είναι εκείνα τα δεδομένα εισόδου - εξόδου που χρησιμοποιούνται για την εκμάθηση (εύρεση των παραμέτρων) του μοντέλου.
- **Δεδομένα Ελέγχου** (Test Data). Είναι εκείνα τα δεδομένα που χρησιμοποιούνται για την μέτρηση της απόδοσης του μοντέλου.

Συνήθως, τα δεδομένα εκμάθησης και τα δεδομένα ελέγχου σχηματίζουν δύο διαφορετικά σύνολα. Αν χρησιμοποιήσουμε τα δεδομένα εκμάθησης για να αξιολογήσουμε την απόδοση ενός μοντέλου, το σφάλμα διασποράς πρακτικά δεν θα ανιχνευθεί. Το σφάλμα μοντελοποίησης στα δεδομένα εκμάθησης αποτελείται σχεδόν αποκλειστικά από το σφάλμα πόλωσης. Συνεπώς, αν αυξήσουμε την πολυπλοκότητα του μοντέλου (περισσότερες συναρτήσεις βάσεις άρα και παράμετροι), θα παρατηρήσουμε μείωση του σφάλματος μοντελοποίησης. Όμως, αν χρησιμοποιήσουμε ως δεδομένα ελέγχου ένα σύνολο διαφορετικό των δεδομένων εκμάθησης, θα παρατηρήσουμε μείωση της απόδοσης του μοντέλου, όταν το επίπεδο της πολυπλοκότητας υπερβεί κάποιο κατώφλι.

Αν αγνοήσουμε το παραπάνω γεγονός και χρησιμοποιήσουμε τα δεδομένα εκμάθησης για την μέτρηση της απόδοσης, είναι πολύ πιθανό να οδηγηθούμε σε υπέρ του δέοντος πολύπλοκα μοντέλα, τα οποία θα αποδίδουν ικανοποιητικά στα δεδομένα εκμάθησης, αλλά θα εμφανίζουν μειωμένη απόδοση σε δεδομένα ελέγχου. Το φαινόμενο ονομάζεται *υπερεκμάθηση* (overfitting). Σε αντιδιαστολή, η χρήση ενός υπεραπλουστευμένου μοντέλου οδηγεί σε μεγάλο σφάλμα πόλωσης και μικρό σφάλμα διασποράς. Το φαινόμενο ονομάζεται *υποεκμάθηση* (undefitting).

Και στις δύο περιπτώσεις, το μοντέλο που προκύπτει είναι χαμηλής ποιότητας (μεγάλο σφάλμα μοντελοποίησης). Ποιο επικίνδυνη όμως θα χαρακτηρίζαμε την περίπτωση της υπερεκμάθησης με την έννοια ότι τα αποτελέσματά της εμφανίζονται στα δεδομένα ελέγχου, όχι όμως και στα δεδομένα εκμάθησης. Αντίθετα, η υποεκμάθηση γίνεται φανερή ακόμα και στην φάση της εκμάθησης και συνεπώς, είναι άμεσα αντιληπτή στον χρήστη.

5.2 Αξιολόγηση Μοντέλου

Από την ανάλυση της προηγούμενης ενότητας έγινε ξεκάθαρο ότι η ποιότητα ενός μοντέλου, δηλαδή το πόσο καλά περιγράφει την συμπεριφορά του πραγματικού συστήματος (ελάχιστο σφάλμα μοντελοποίησης), εκτιμάτε όταν το χρησιμοποιούμε σε δεδομένα του συστήματος τα οποία δεν χρησιμοποιήθηκαν στην φάση της εκμάθησης. Προφανώς αναφερόμαστε στα δεδομένα ελέγχου.

Ο απλούστερος τρόπος αξιολόγησης ενός μοντέλου, είναι να το συνθέσουμε χρησιμοποιώντας τα δεδομένα εκμάθησης και στην συνέχεια να εκτιμήσουμε την απόδοσή του κάνοντας χρήση των δεδομένων ελέγχου. Για να υλοποιηθεί μια τέτοια προσέγγιση, θα πρέπει το σύνολο των δεδομένων να χωριστεί σε δύο ομάδες, στα δεδομένα εκμάθησης και στα δεδομένα ελέγχου. Αν το συνολικό πλήθος των δεδομένων είναι αρκετά μεγάλο ένας τέτοιος διαχωρισμός είναι πάντα εφικτός. Βέβαια, θα πρέπει να υπάρξει πρόβλεψη τα δεδομένα από κάθε ομάδα να είναι εκτός από αρκετά και αντιπροσωπευτικά. Ένα σύνολο δεδομένων είναι αντιπροσωπευτικό, αν καλύπτει εξίσου καλά όλες τις περιοχές λειτουργίας του συστήματος. Αν από τα δεδομένα εκμάθησης απουσιάζουν κάποιες περιοχές λειτουργίας τότε αυτή η πληροφορία δεν θα ενσωματωθεί στο μοντέλο, μ΄ αποτέλεσμα να έχουμε σημαντικό σφάλμα μοντελοποίησης όταν το πραγματικό σύστημα βρεθεί να λειτουργεί σ΄ αυτές τις περιοχές. Από την άλλη μεριά, αν τα δεδομένα ελέγχου δεν είναι αντιπροσωπευτικά, η αξιολόγηση του μοντέλου καθίσταται αναξιόπιστη.

Εγκάρσια αξιολόγηση

Προηγουμένως υποθέσαμε ότι το συνολικό πλήθος των δεδομένων που έχουμε στην διάθεσή μας είναι αρκούντως μεγάλο ώστε να επιτρέπει τον διαχωρισμό σε δεδομένα εκμάθησης και δεδομένα ελέγχου. Στην πράξη όμως πολύ συχνά ερχόμαστε αντιμέτωποι με το πρόβλημα της έλλειψης δεδομένων. Μια τεχνική που μπορεί να χρησιμοποιηθεί σε τέτοιες περιπτώσεις είναι η *εγκάρσια αξιολόγηση* (cross validation). Σύμφωνα μ΄ αυτή, το σύνολο των δεδομένων έστω N χωρίζεται σε M τμήματα όπου το καθένα περιέχει N/M δεδομένα. Τα $M-1$ τμήματα απαρτίζουν τα δεδομένα εκμάθησης και το τελευταίο τα δεδομένα ελέγχου, πάνω στο οποίο αξιολογούμε την συμπεριφορά του μοντέλου, υπολογίζοντας για παράδειγμα την L_2 νόρμα του σφάλματος μοντελοποίησης. Η διαδικασία επαναλαμβάνεται μ΄ όλους τους M διαφορετικούς συνδυασμούς (δες Σχ. 5.2). Επειδή ακριβώς σε κάθε επανάληψη τόσο τα δεδομένα εκμάθησης, όσο και τα δεδομένα ελέγχου είναι διαφορετικά, η L_2 νόρμα του σφάλματος μοντελοποίησης θα διαφέρει και αυτή από επανάληψη σε επανάληψη. Προκειμένου να προκύψει αξιόπιστη εκτίμηση της ποιότητας λαμβάνουμε την μέση τιμή όλων των L_2 νορμών.

Είναι προφανές, ότι η εγκάρσια αξιολόγηση έχει την τάση να χρησιμοποιεί την συντριπτική πλειοψηφία του συνόλου των δεδομένων για εκμάθηση και πολύ λιγότερα για έλεγχο. Για τον λόγο

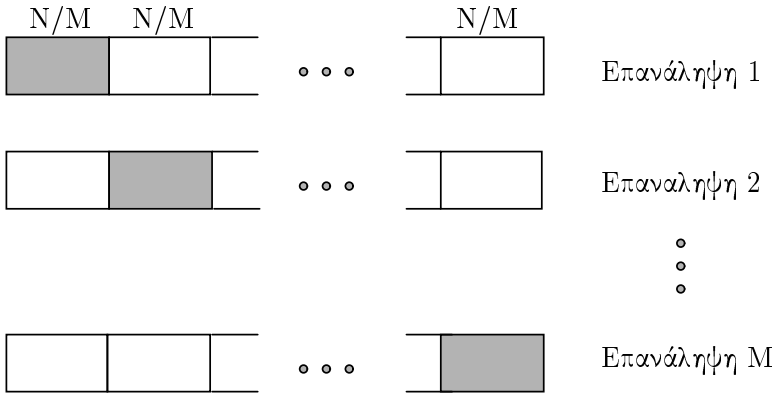

Σχήμα 5.2: Γραφική αναπαράσταση της λειτουργίας της εγκάρσιας αξιολόγησης. Σε κάθε επανάληψη, το γραμμοσκιασμένο τμήμα συμβολίζει τα δεδομένα ελέγχου. Το μήκος του κάθε τμήματος είναι N/M όπου N το συνολικό πλήθος των δεδομένων.

αυτό προσφέρεται για περιπτώσεις μικρού αριθμού δεδομένων. Τυπική τιμή του M είναι το 10.

Η τεχνική μπορεί να χρησιμοποιηθεί και για $M = N$. Τότε μετονομάζεται σε *'άφησε ένα έξω'* μέθοδος και χρησιμοποιείται όταν ο συνολικός αριθμός των δεδομένων είναι πολύ μικρός, μια και απαιτεί σημαντικό υπολογιστικό φόρτο. Στην ειδική αυτή περίπτωση από τα N δεδομένα, κάθε φορά τα $N - 1$ χρησιμοποιούνται για εκμάθηση και ένα για έλεγχο. Πάλι η μέση τιμή των L_2 νορμών λαμβάνεται για την εκτίμηση της ποιότητας του μοντέλου.

Κριτήρια θεωρίας πληροφοριών

Μια εναλλακτική πρόταση αξιολόγησης μοντέλων στην υπολογιστικά απαιτητική τεχνική της εγκάρσιας αξιολόγησης, αποτελεί η χρήση κριτηρίων δανεισμένων από την θεωρία των πληροφοριών. Εδώ τα δεδομένα δεν χωρίζονται σε δεδομένα εκμάθησης και δεδομένα ελέγχου. Αντίθετα, όλα τα δεδομένα χρησιμοποιούνται αποκλειστικά για εκμάθηση. Προκειμένου να αποφύγουμε τις δυσάρεστες συνέπειες της υπερεκμάθησης, εισάγεται μια συνάρτηση ποινής στην πολυπλοκότητα (πλήθος παραμέτρων). Το κριτήριο που σχηματίζεται είναι συνάρτηση του συνολικού σφάλματος μοντελοποίησης και της πολυπλοκότητας.

$$\text{Κριτήριο}=\text{Κ}(\text{συνολικό σφάλμα, πολυπλοκότητα}) \tag{5.2.1}$$

Ως καλύτερο, ορίζεται εκείνο το μοντέλο στο οποίο αντιστοιχεί η μικρότερη τιμή της (5.2.1). Κάθε λογική συνάρτηση ποινής για την πολυπλοκότητα που εμφανίζεται στην (5.2.1) θα πρέπει να αυξάνει με τον αριθμό των παραμέτρων του μοντέλου.

Ξεκινώντας από διαφορετικές στατιστικές υποθέσεις, έχουν προταθεί διάφορα κριτήρια. Τα πιο σημαντικά συνοψίζονται παρακάτω:

- **Κριτήριο του** `Akaike (Akaike's Information Criterion (AIC))`**:**

$$AIC = N \ln(I(\theta)) + \rho n \tag{5.2.2}$$

με τυπική επιλογή $\rho = 2$.

- **Κριτήριο** `Bayes (Bayesian Information Criterion (BIC)):`

$$BIC = N\ln(I(\theta)) + \ln(N)n \tag{5.2.3}$$

- **Κριτήριο βασισμένο στον νόμο του** `Khinchin's (Khinchin's Information Criterion (KIC)):`

$$KIC = N\ln(I(\theta)) + 2\rho\ln(\ln(N))n \tag{5.2.4}$$

- **Κριτήριο σφάλματος τελικής πρόβλεψης** `(Final Prediction Error (FPE)):`

$$FPE = N\ln(I(\theta)) + N\ln\left(\frac{N+n}{N-n}\right) \tag{5.2.5}$$

- **Κριτήριο ελαχιστοποίησης δομικού κινδύνου** `(Structural Risk Minimization (SRM)):`

$$SRM = \frac{I(\theta)}{\rho_1\sqrt{\frac{n\ln(2N)-\ln(n)+\rho_2}{N}}} \tag{5.2.6}$$

  Αν η υπόριζος ποσότητα γίνει αρνητική, θέτουμε $SRM = \infty$, που σημαίνει ότι έχουμε υπερβεί την μέγιστη ανεκτή πολυπλοκότητα του μοντέλου.

Σ' όλα τα παραπάνω κριτήρια, N είναι ο αριθμός των δεδομένων, n ο αριθμός των παραμέτρων και

$$I(\theta) = \frac{1}{N}\sum_{j=1}^{N}(y_j - \hat{y}_j)^2$$

Πρέπει να σημειωθεί ότι οι παράμετροι του μοντέλου προσδιορίζονται με τις τεχνικές που αναφέρθηκαν στα Κεφάλαια 3, 4. Όλα τα κριτήρια χρησιμοποιούνται για σύγκριση μεταξύ μοντέλων και όχι για αξιολόγηση πάνω σ' ένα ξεχωριστό σύνολο δεδομένων ελέγχου. Τέλος, κάποια από τα κριτήρια περιέχουν και ρυθμιστικές παραμέτρους ρ, οι οποίες γενικά δεν προσδιορίζονται εύκολα.

5.3 Επιλογή Δομής Μοντέλου

Στην ενότητα αυτή θα αναφερθούμε σε κάποιες τεχνικές προσδιορισμού της δομής ενός μοντέλου, με σκοπό την βελτίωση της απόδοσής του. Υπάρχουν δύο κατηγορίες τεχνικών προσδιορισμού δομής. Οι άμεσες και οι έμμεσες. Στις άμεσες, η ελαχιστοποίηση του σφάλματος μοντελοποίησης συντελείται με την εξέταση μοντέλων με διαφορετικό αριθμό παραμέτρων. Αντίθετα στις έμμεσες τεχνικές, ο αριθμός των παραμέτρων του μοντέλου δεν διαφοροποιείται. Παραταύτα, η πολυπλοκότητα του μοντέλου μεταβάλλεται.

Άμεσες τεχνικές προσδιορισμού δομής μοντέλου

Η επιλογή της δομής ενός μοντέλου μπορεί να συντελεστεί επεμβαίνοντας απ' ευθείας στον αριθμό των παραμέτρων του μοντέλου, υλοποιώντας για παράδειγμα μοντέλα με $1, 2, \ldots, n$ παραμέτρους, και αξιολογώντας τα. Οι άμεσες τεχνικές χωρίζονται στις παρακάτω κατηγορίες:

1. **Γενικές Μέθοδοι.** Στην κατηγορία αυτή συγκρίνονται μοντέλα διαφορετικών πολυπλοκοτήτων. Δεν απαιτείται η ύπαρξη συγκεκριμένης σχέσης μεταξύ τους. Για παράδειγμα, θα μπορούσαμε να συγκρίνουμε όλα τα μοντέλα από κάποια ελάχιστη, έως κάποια μέγιστη πολυπλοκότητα. Με τον τρόπο αυτό, θα μπορούσε να βρεθεί η βέλτιστη λύση. Το υπολογιστικό κόστος όμως είναι τεράστιο.

2. **Προσθετική Δόμηση.** Στην κατηγορία αυτή ξεκινάμε μ' ένα πολύ απλό μοντέλο. Σε κάθε επανάληψη του αλγορίθμου αυξάνουμε την πολυπλοκότητά του, προσθέτοντας από παραμέτρους έως ολόκληρες υποδομές (substructures). Η φιλοσοφία των τεχνικών της προσθετικής δόμησης, στηρίζεται στο δόγμα 'δοκίμασε τις απλές λύσεις πρώτα'. Το πλεονέκτημά τους είναι ότι δεν απαιτείται η έτσι και αλλιώς υλοποίηση πολύπλοκων μοντέλων. Πολλές φορές μάλιστα η διαδικασία δόμησης τερματίζεται σε μοντέλα σχετικά χαμηλής πολυπλοκότητας.

3. **Αφαιρετική Δόμηση.** Στην κατηγορία αυτή λειτουργούμε με ακριβώς την αντίθετη φιλοσοφία από αυτή της προσθετικής δόμησης. Τώρα εκκινούμε απ' ένα αρκούντως πολύπλοκο μοντέλο το οποίο αναμένεται να αποτελεί 'υπερσύνολο' του βέλτιστου, και σε κάθε επανάληψη του αλγορίθμου αφαιρούμε παραμέτρους ή/και υποδομές. Η αφαιρετική δόμηση είναι σαφώς υπολογιστικά πιο απαιτητική και κατ' επέκταση χρονοβόρα μέθοδος.

4. **Επιλογή ανά Βήμα.** Η κατηγορία αυτή συνδυάζει την προσθετική με την αφαιρετική δόμηση. Ξεκινάμε με κάποια απλή δομή και σε κάθε επανάληψη του αλγορίθμου λειτουργούμε αρχικά προσθετικά και στην συνέχεια αφαιρετικά. Η επιλογή ανά βήμα οδηγεί συνήθως σε καλύτερα αποτελέσματα από την καθαρή προσθετική ή αφαιρετική δόμηση, απαιτώντας ενδιάμεσο υπολογιστικό φόρτο.

Έμμεσες τεχνικές προσδιορισμού δομής μοντέλου

Οι έμμεσες τεχνικές επηρεάζουν την πολυπλοκότητα του μοντέλου, χωρίς την μεταβολή του αριθμού των παραμέτρων. Στην διεθνή βιβλιογραφία, οι έμμεσες τεχνικές ονομάζονται και ρυθμιστικές (regularization methods).

Γενικές αρχές

Στις έμμεσες τεχνικές θέλουμε να μοντελοποιήσουμε κάποια συνάρτηση του σφάλματος μοντελοποίησης μεταβάλλοντας τις παραμέτρους του μοντέλου, με την διαφορά ότι πρέπει επιπλέον να ικανοποιούνται κάποιοι περιορισμοί ή κριτήρια. Επειδή ακριβώς ένα πλήθος βαθμών ελευθερίας (παραμέτρων) δεσμεύονται για την ικανοποίηση των περιορισμών - κριτηρίων, δεν χρησιμοποιούνται

όλες οι παράμετροι για την ελαχιστοποίηση του σφάλματος μοντελοποίησης. Εκείνοι που χρησιμοποιούνται ονομάζονται *ενεργές παράμετροι* (effective parameters). Όλες οι άλλοι ονομάζονται *ανεπιθύμητες παράμετροι* (spurious parameters). Αν το ρυθμιστικό φαινόμενο είναι ισχυρό, ο αριθμός των ενεργών παραμέτρων προσεγγίζει το μηδέν, ενώ αν είναι ασθενές προσεγγίζει τον συνολικό αριθμό των παραμέτρων. Το παράδειγμα που ακολουθεί ξεκαθαρίζει τις έννοιες.

Παράδειγμα 5.3.1 Θεωρείστε το μοντέλο:

$$y = \theta_1 + \theta_2 x + \theta_3 x^2$$

όπου οι παράμετροι $\theta_1, \theta_2, \theta_3$ πρέπει να ικανοποιούν τον περιορισμό:

$$\theta_1 + \theta_2 + \theta_3 = \rho$$

Είναι προφανές ότι από τις τρεις παραμέτρους, η μία προσδιορίζεται από τις άλλες δύο προκειμένου να ικανοποιηθεί ο περιορισμός. Συνεπώς, στο παράδειγμά μας έχουμε δύο ενεργές παραμέτρους και μια ανεπιθύμητη. Παραταύτα, δεν είναι ξεκάθαρο ποια από τις τρεις είναι η ανεπιθύμητη. Θεωρητικά, μπορεί να είναι οποιαδήποτε από τις $\theta_1, \theta_2, \theta_3$.

Ρυθμιστικότητα μέσω συναρτήσεων ποινής

Μια και ο αριθμός των ενεργών παραμέτρων μειώνεται κατά την ρυθμιστικότητα, αναμένουμε την εξομάλυνση της εξόδου του μοντέλου. Η ομαλότητα της εξόδου του μοντέλου είναι επιθυμητή ιδιότητα διότι τα περισσότερα αν όχι όλα τα φυσικά συστήματα εμφανίζουν ομαλή έξοδο. Μια ρυθμιστική τεχνική αποτελεί η ενσωμάτωση στην αρχική συνάρτηση του σφάλματος μοντελοποίησης μιας συνάρτησης ποινής ενάντια στην τυχόν ύπαρξη μη ομαλής συμπεριφοράς. Το κριτήριο που καλούμαστε επομένως να ελαχιστοποιήσουμε είναι της μορφής:

$$\text{Κριτήριο} = \text{Συνάρτηση σφάλματος μοντελοποίησης} + \text{Συνάρτηση ποινής} \tag{5.3.1}$$

Ως συνάρτηση σφάλματος μοντελοποίησης συνήθως χρησιμοποιούμε την L_2 νόρμα, ενώ μια τυπική επιλογή συνάρτησης ποινής αποτελεί η δεύτερη παράγωγος της εξόδου του μοντέλου ως προς τις εισόδους του. Για N δεδομένα εκμάθησης:

$$\text{Συνάρτηση Ποινής} = \gamma \sum_{i=1}^{N} \left| \frac{\partial^2 f(u(i), \theta)}{\partial u(i)^2} \right|^2 \tag{5.3.2}$$

όπου θεωρήσαμε μοντέλο της μορφής $\hat{y} = f(u, \theta)$. Η παράμετρος γ, αποτελεί συντελεστή βαρύτητας που ενισχύει για $\gamma \to \infty$ ή υποβαθμίζει για $\gamma \to 0$ την συνεισφορά της συνάρτησης ποινής στο κριτήριο ελαχιστοποίησης.

Η (5.3.2) πριμοδοτεί τα γραμμικά μοντέλα όπου $\frac{\partial^2 f(u(i),\theta)}{\partial u(i)^2} = 0$. Συνεπώς, μπορούμε να θεωρήσουμε την (5.3.2) ως το μέσο εισαγωγής της όποιας εκ των προτέρων γνώσης έχουμε για το σύστημά μας.

Λόγω του ότι ο ακριβής υπολογισμός των δεύτερων παραγώγων της εξόδου του μοντέλου ως προς τις εισόδους του είναι δαπανηρός, καθιστώντας το πρόβλημα της βελτιστοποίησης πολύπλοκο, στην πράξη χρησιμοποιούμε διάφορες προσεγγίσεις της συνάρτησης ποινής. Για παράδειγμα στην περίπτωση των γραμμικά παραμετροποιημένων μοντέλων, επιθυμούμε το ρυθμιστικό πρόβλημα να παραμείνει γραμμικό ως προς τις παραμέτρους. Επιλέγουμε λοιπόν ως μορφή κριτηρίου (5.3.1) την:

$$K = |\tilde{y}|^2 + \gamma|\theta|^2 \tag{5.3.3}$$

όπου με $\tilde{y}$ δηλώνουμε το σφάλμα μοντελοποίησης. Το κριτήριο (5.3.3) οδηγεί όλες τις παραμέτρους του μοντέλου στην γειτονιά του μηδενός. Αν γνωρίζουμε ότι οι παράμετροι θ πρέπει να βρίσκονται κοντά στο $\theta^\star$, χρησιμοποιούμε το κριτήριο:

$$K = |\tilde{y}|^2 + \gamma|\theta - \theta^\star|^2 \tag{5.3.4}$$

Η λογική πίσω από την χρήση του (5.3.3) και κατ' επέκταση του (5.3.4) είναι ότι αναμένουμε να μεταβληθούν εκείνες οι παράμετροι που έχουν ασθενή επιρροή στο σφάλμα μοντελοποίησης $\tilde{y}$, ενώ όλες οι άλλες θα μείνουν πρακτικά αμετάβλητες. Μετά την φάση της εκμάθησης, οι μη σημαντικές για το $\tilde{y}$ παράμετροι θα οδηγηθούν κοντά στο μηδέν και επομένως σε δεύτερο στάδιο μπορούν να απομακρυνθούν. Η διαδικασία αυτή αποτελεί τυπικό συνδυασμό ρυθμιστικής τεχνικής με άμεση τεχνική προσδιορισμού δομής μοντέλου.

Ρυθμιστικότητα λόγω πρόωρου τερματισμού

Μια άλλη σημαντική τεχνική είναι ο πρόωρος τερματισμός. Εφαρμόζεται σε περιπτώσεις χρήσης αναδρομικών μεθόδων προσδιορισμού των παραμέτρων του μοντέλου. Σύμφωνα με την μέθοδο, η εκμάθηση δεν διαρκεί έως ότου οι παράμετροι του μοντέλου συγκλίνουν στις βέλτιστες τιμές τους. Σε κάθε επανάληψη του αναδρομικού αλγορίθμου εκμάθησης το μοντέλο που προκύπτει αξιολογείται πάνω σε δεδομένα ελέγχου (διαφορετικά από τα δεδομένα εκμάθησης) και μόλις το σφάλμα ελέγχου ελαχιστοποιηθεί διακόπτουμε την εκμάθηση. Η διαδικασία φαίνεται στο Σχ. 5.3.

Διαισθητικά, κατά την φάση της εκμάθησης, οι πιο σημαντικές παράμετροι θα κινηθούν ταχύτερα προς τις βέλτιστες σε σχέση με τις λιγότερο σημαντικές. Συνεπώς, ο πρόωρος τερματισμός επιτρέπει στις σημαντικές παραμέτρους να συγκλίνουν και να γίνουν οι ενεργές παράμετροι του μοντέλου, ενώ οι υπόλοιπες θα παραμείνουν πρακτικά κοντά στις αρχικές τους τιμές.

Η δημοτικότητα της μεθόδου οφείλεται στην απλότητά της. Επιπλέον δεν έχει σημαντικό υπολογιστικό κόστος και δεν απαιτείται η σύγκλιση των παραμέτρων. Συνεπώς, μπορούν να χρησιμοποιηθούν και αναδρομικές μέθοδοι με χαμηλή ταχύτητα σύγκλισης. Είναι σημαντικό να παρατηρήσουμε ότι η μέθοδος εφαρμόζεται με επιτυχία όταν έχουμε υπερ-παραμετροποιημένα μοντέλα. Διαφορετικά, όλες οι παράμετροι τείνουν να γίνουν ενεργές.

Ρυθμιστικότητα μέσω περιορισμών

Όπως είδαμε και στο Παράδειγμα 5.3.1, η ύπαρξη περιορισμών που πρέπει να ικανοποιούν οι παράμετροι του μοντέλου έχει ρυθμιστικές ιδιότητες (επηρεάζει τον αριθμό των ενεργών παραμέτρων). Οι περιορισμοί διακρίνονται σε:

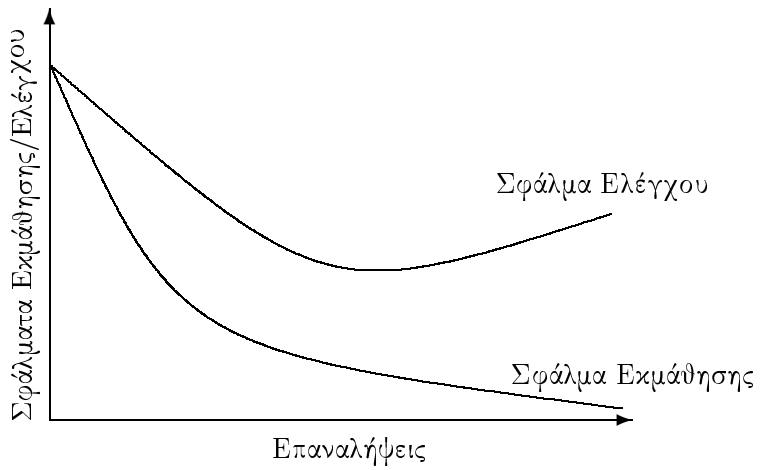

Σχήμα 5.3: Αναπαράσταση της μεθόδου του πρόωρου τερματισμού. Όταν ελαχιστοποιηθεί το σφάλμα ελέγχου τερματίζουμε την φάση της εκμάθησης.

1. **Εξισωτικούς Περιορισμούς.** Στην περίπτωση ύπαρξης εξισωτικού περιορισμού, η μία παράμετρος προσδιορίζεται πλήρως από τις υπόλοιπες. Το Παράδειγμα 5.3.1 είναι διαφωτιστικό.

2. **Ανισωτικούς Περιορισμούς.** Στην περίπτωση ύπαρξης ανισωτικών περιορισμών, αν οι βέλτιστες τιμές των παραμέτρων για το αντίστοιχο πρόβλημα χωρίς περιορισμούς, ικανοποιούν όλους τους περιορισμούς, τότε δεν υφίσταται ρυθμιστικότητα. Διαφορετικά, αν το βέλτιστο για το αντίστοιχο χωρίς περιορισμούς πρόβλημα ανήκει σε μη εφικτή περιοχή του χώρου των παραμέτρων, τότε οι ανισωτικοί περιορισμοί θα απαγορεύουν σε κάποιες παραμέτρους να 'πιάσουν' τις βέλτιστες τιμές τους, οπότε και επιτυγχάνεται ρυθμιστικότητα.